

TRƯỜNG ĐẠI HỌC FPT

KHOA CÔNG NGHỆ THÔNG TIN

BỘ MÔN TRÍ TUỆ NHÂN TẠO

Đề tài:

Phân tích và dự đoán giá nhà tại bang New South Wales (NSW), Úc

Môn học: ADY201m

Sinh viên thực hiện:

Trần Kiến Quốc SE190250

Vũ Đức SE192458

Dương Ngọc Hân SE190041

Giảng viên hướng dẫn:

Lê Võ Minh Thư

Ngày 3 tháng 11 năm 2025



FPT UNIVERSITY

Mục lục

1	Phân tích đề bài	1
1.1	Vấn đề cần giải quyết	1
1.2	Mục tiêu	1
1.3	Cách tiếp cận bài toán	1
2	Tiền xử lý dữ liệu	3
2.1	Tổng quan dữ liệu	3
2.2	Làm sạch dữ liệu	5
2.2.1	Xử lý dữ liệu thiếu	5
2.2.2	Loại bỏ bản ghi trùng lặp và không hợp lệ	8
2.2.3	Chuẩn hoá dữ liệu	8
2.2.4	Tạo đặc trưng mới	10
2.2.5	Phát hiện và loại bỏ ngoại lệ	11
3	Phân tích dữ liệu với SQL	14
3.1	Phương pháp thực hiện	14
3.2	Các truy vấn SQL	15
3.2.1	Thống kê mức giá trung bình của bất động sản theo từng bang	15
3.2.2	Thống kê số lượng của từng loại hình bất động sản theo bang NSW	16
3.2.3	Thống kê mức giá trung bình theo từng cấu hình bất động sản	17
3.2.4	Thống kê số lượng bất động sản theo bang	18
3.2.5	Thống kê biên độ giá theo từng loại hình bất động sản	19
3.2.6	Thống kê mức giá bất động sản trung bình theo khu vực	20
3.2.7	Thống kê các tuyến đường theo mức giá bất động sản trung bình tại NSW	22
3.2.8	Thống kê các tháng có giá trung bình cao nhất tại NSW	23
3.2.9	Thống kê các tháng có số lượng giao dịch cao nhất tại NSW	24
3.2.10	Thống kê tổng giá trị giao dịch bất động sản theo mã vùng tại NSW	25
4	Phân tích dữ liệu với Pandas	27
4.1	Phương pháp thực hiện	27
4.2	Các phân tích với Pandas	27

4.2.1	Thống kê giá trung bình trên mỗi mét vuông theo khu vực tại NSW	28
4.2.2	Thống kê các tuyến đường theo số lượng giao dịch bất động sản tại NSW . .	28
4.2.3	Thống kê mã vùng theo mức giá trung bình NSW	29
4.2.4	Phân tích mối quan hệ giữa số lần giao dịch và giá bất động sản tại NSW . .	30
4.2.5	Phân tích tốc độ biến động giá trung bình theo tháng tại NSW	31
4.2.6	So sánh giá trung bình theo loại hình bất động sản giữa các bang tại Úc . .	32
4.2.7	Thống kê tỷ lệ bất động sản có chỗ đậu xe theo bang tại Úc	33
4.2.8	Phân tích ảnh hưởng của chỗ đậu xe đến giá trị bất động sản theo từng bang	34
4.2.9	Phân tích độ biến động giá (rủi ro tương đối) theo loại hình và bang	35
4.2.10	Thống kê loại hình bất động sản chiếm ưu thế tại các khu vực suburb	36
5	Trực quan hóa dữ liệu với Python	38
5.1	Bản đồ nhiệt phân bố giá bất động sản tại bang New South Wales	38
5.1.1	Mục tiêu	38
5.1.2	Kết luận	39
5.2	So sánh giá bất động sản theo loại hình (Type) trên khu vực New South Wales . . .	39
5.2.1	Mục tiêu	39
5.2.2	Kết luận	39
5.3	Bản đồ cụm không gian LISA của giá bất động sản tại bang New South Wales . . .	40
5.3.1	Mục tiêu	40
5.3.2	Kết luận	41
5.4	5 loại hình bất động sản được bán nhiều nhất	42
5.4.1	Mục tiêu	42
5.4.2	Kết luận	42
5.5	Mật độ (Hexbin) giá và diện tích bất động sản tại bang New South Wales (NSW) .	43
5.5.1	Mục tiêu	43
5.5.2	Kết luận	44
5.6	Phân bố giá bất động sản tại Sydney	44
5.6.1	Mục tiêu	44
5.6.2	Kết luận	45
5.7	So sánh giá bất động sản giữa các loại hình nhà ở tại New South Wales	46

5.7.1	Mục tiêu	46
5.7.2	Kết luận	47
5.8	Mối quan hệ giữa giá trung vị bất động sản và khoảng cách tới trung tâm Sydney .	48
5.8.1	Mục tiêu	48
5.8.2	Kết luận	48
5.9	Phân bố loại hình bất động sản trong phạm vi 10 km từ bờ biển tại New South Wales	49
5.9.1	Mục tiêu	49
5.9.2	Kết luận	49
5.10	Phân bố loại hình bất động sản tại bang có giá trung bình trên mỗi mét vuông cao nhất (New South Wales)	50
5.10.1	Mục tiêu	50
5.10.2	Kết luận	51
6	Xây dựng mô hình	52
6.1	Mục tiêu	52
6.2	Linear Regression	52
6.2.1	Tổng quan lý thuyết	52
6.2.2	Hàm mất mát (Loss Function) và hàm mục tiêu (Cost Function)	52
6.2.3	Chỉ số đánh giá hiệu năng	53
6.2.4	Triển khai	53
6.2.5	Kết quả và nhận xét	54
6.3	Decision Tree Regression	54
6.3.1	Tổng quan lý thuyết	54
6.3.2	Triển khai	55
6.3.3	Kết quả và nhận xét	56
6.4	Random Forest Regression	56
6.4.1	Tổng quan lý thuyết	56
6.4.2	Triển khai	57
6.4.3	Kết quả và nhận xét	57
6.5	Gradient Boosting Regression	58
6.5.1	Tổng quan lý thuyết	58

6.5.2	Triển khai	59
6.5.3	Kết quả và nhận xét	59
6.6	XGBoost Regression	60
6.6.1	Tổng quan lý thuyết	60
6.6.2	Triển khai	60
6.6.3	Kết quả và nhận xét	61
6.7	Tối ưu siêu tham số bằng Optuna	62
6.7.1	Tổng quan	62
6.7.2	Không gian tìm kiếm siêu tham số	62
6.7.3	Kết quả tối ưu hoá	63
6.8	Kết luận	65
6.8.1	So sánh tổng hợp	65
6.8.2	Nhận xét	65

1 Phân tích đề bài

1.1 Vấn đề cần giải quyết

Giá nhà tại bang New South Wales (NSW), Úc, chịu ảnh hưởng bởi nhiều yếu tố như vị trí địa lý, số lượng phòng, diện tích, và khoảng cách đến trung tâm thành phố. Việc ước lượng chính xác giá nhà là một bài toán quan trọng giúp người mua, người bán và nhà đầu tư ra quyết định hiệu quả hơn. Tuy nhiên, dữ liệu thực tế thường rất lớn, không đồng nhất và chứa nhiều giá trị thiếu, gây khó khăn cho việc phân tích và dự đoán.

1.2 Mục tiêu

Xây dựng một mô hình dự đoán giá nhà tại bang NSW dựa trên các yếu tố liên quan như tọa độ, số phòng, diện tích, và khoảng cách đến trung tâm. Mục tiêu là tìm ra mô hình có độ chính xác cao nhất, giúp hỗ trợ việc định giá và phân tích xu hướng thị trường bất động sản tại khu vực này.

1.3 Cách tiếp cận bài toán

Quy trình thực hiện được chia thành 7 bước chính như sau:

1. **Xác định bài toán:** Xác định mục tiêu là dự đoán giá nhà tại bang NSW (Úc) dựa trên các đặc trưng chính.
2. **Thu thập và tiền xử lý dữ liệu:** Sử dụng công cụ *Octoparse* để cào dữ liệu từ các trang web bất động sản và tải thêm dữ liệu từ trang chính thức của NSW. Sau đó làm sạch và chuẩn hóa dữ liệu.
3. **Phân tích dữ liệu bằng SQL:** Dùng SQL để lọc, thống kê và truy vấn dữ liệu nhằm hiểu rõ cấu trúc và chất lượng thông tin.
4. **Phân tích dữ liệu bằng Python (Pandas):** Sử dụng thư viện *Pandas* để xử lý, kết hợp dữ liệu và tạo thêm các đặc trưng.
5. **Trực quan hóa bằng Python:** Dùng các thư viện *Matplotlib* và *Seaborn* để biểu diễn phân bố giá, mối tương quan giữa các biến và phát hiện giá trị ngoại lai.

6. **Xây dựng mô hình dự đoán:** Huấn luyện các mô hình *Linear Regression*, *XGBoost*, và *LightGBM*, sau đó so sánh hiệu năng để chọn mô hình tối ưu.
7. **Trực quan hóa kết quả bằng Power BI:** Kết nối dữ liệu đầu ra vào *Power BI* để xây dựng dashboard thể hiện xu hướng giá nhà và hiệu quả mô hình dự đoán.

2 Tiền xử lý dữ liệu

2.1 Tổng quan dữ liệu

Trong đề tài này, hai tập dữ liệu chính được sử dụng:

- **NSW Property Sales:** dữ liệu công khai về các giao dịch bất động sản tại bang New South Wales (NSW), gồm hơn 1.8 triệu dòng và 20 cột.
- **Domain Real Estate:** dữ liệu thu thập từ trang Domain.com.au, gồm 16.864 bất động sản đang được rao bán.

```
1 print("Domain data shape:", df_domain.shape)
2 print("NSW Sales data shape:", df_nsw.shape)
```

Domain data shape: (16864, 18)

NSW Sales data shape: (1827868, 20)

Nhận xét: Bộ NSW có kích thước rất lớn (hơn 1.8 triệu bản ghi), trong khi Domain nhỏ hơn nhiều.

Bảng 1: Mô tả các cột trong bộ dữ liệu Domain

Tên cột	Kiểu dữ liệu	Mô tả
Address_URL	object	Đường dẫn (URL) đến trang chi tiết của bất động sản trên website gốc.
Price	float	Giá niêm yết của bất động sản.
Address	object	Địa chỉ đầy đủ của bất động sản (bao gồm số nhà, tên đường, khu vực, bang và mã bưu điện).
Beds	int	Số lượng phòng ngủ.
Baths	int	Số lượng phòng tắm.
Parking	int	Số chỗ đậu xe.

Size	float	Diện tích của bất động sản.
Type	object	Loại hình bất động sản.
format	object	Kiểu định dạng của trường Address.
unit	object	Số unit hoặc căn hộ (nếu có), tách riêng từ địa chỉ.
street_number	object	Số nhà hoặc số đường.
street_name	object	Tên đường.
lot_number	float	Số lô đất.
suburb	object	Tên khu vực hoặc phường/xã.
state	object	Bang hoặc vùng hành chính.
postcode	int	Mã bưu điện của khu vực.
lat	float	Vĩ độ của bất động sản.
lon	float	Kinh độ của bất động sản.

Bảng 2: Mô tả các cột trong bộ dữ liệu NSW

Tên cột	Kiểu dữ liệu	Mô tả
Property ID	float64	Mã định danh duy nhất cho bất động sản.
Sale counter	int64	Số thứ tự giao dịch hoặc lần bán của bất động sản.
Download date / time	object	Ngày và giờ tải dữ liệu.
Property name	object	Tên chính thức hoặc tên dự án của bất động sản.
Property unit number	object	Số unit hoặc căn hộ (nếu là chung cư).
Property house number	object	Số nhà hoặc số đường của bất động sản.

Tên cột	Kiểu dữ liệu	Mô tả
Property street name	object	Tên đường nơi bất động sản tọa lạc.
Property locality	object	Khu vực, phường/xã hoặc thị trấn (suburb/locality).
Property post code	float64	Mã bưu điện của khu vực.
Area	float64	Diện tích của bất động sản.
Area type	object	Loại diện tích được đo (ví dụ: land area, floor area).
Contract date	object	Ngày ký hợp đồng mua bán (dạng chuỗi thời gian).
Settlement date	object	Ngày hoàn tất giao dịch / bàn giao tài sản.
Purchase price	int64	Giá mua hoặc giá giao dịch của bất động sản.
Zoning	object	Mã quy hoạch / vùng sử dụng đất.
Nature of property	object	Tính chất của bất động sản.
Primary purpose	object	Mục đích sử dụng chính của bất động sản.
Strata lot number	float64	Số lô trong hệ thống Strata.
Dealing number	object	Mã hồ sơ hoặc số giao dịch pháp lý liên quan.
Property legal description	object	Mô tả pháp lý chi tiết của bất động sản.

2.2 Làm sạch dữ liệu

2.2.1 Xử lý dữ liệu thiếu

Sử dụng hàm `isna()` và `sum()` để liệt kê các giá trị bị thiếu trong hai bộ dữ liệu.

```
1 df_domain.isna().sum()
```

Address_URL	0
Price	0
Address	0
Beds	2554
Baths	2554
Parking	4219
Size	8472
Type	0
format	0
unit	8963
street_number	1973
street_name	513
lot_number	15404
suburb	0
state	0
postcode	0
lat	6
lon	6
dtype:	int64

```
1 df_nsw.isna().sum()
```

Property ID	220
Sale counter	0
Download date / time	0
Property name	1747346
Property unit number	1199361
Property house number	39390
Property street name	493
Property locality	5
Property post code	131
Area	429118

Area type	429090
Contract date	175
Settlement date	1
Purchase price	0
Zoning	762103
Nature of property	0
Primary purpose	286
Strata lot number	1141943
Dealing number	0
Property legal description	19
dtype: int64	

Sau khi xác định được các cột có nhiều giá trị bị thiếu, tiến hành các bước xử lý như sau:

- Với bộ dữ liệu **domain**:

- Các cột **Beds**, **Baths**, **Parking** được thay thế giá trị thiếu bằng 0 vì đây là các thuộc tính số nguyên, việc để trống có thể hiểu là “không có”.
- Kích thước bất động sản **Size** được ước lượng bằng giá trị trung vị (**median**) của các nhóm cùng loại **Type** và số phòng ngủ **Beds**.
- Với các trường hợp vẫn còn thiếu sau khi gán theo nhóm, giá trị trung vị toàn bộ cột **Size** được sử dụng để điền vào.

- Với bộ dữ liệu **nsw**:

- Các cột phân loại như **Zoning** và **Area type** được điền bằng chuỗi '**unknown**'.
- Cột **Area** được xử lý theo trung bình từng nhóm **Area type**; nếu vẫn còn thiếu, tiếp tục điền bằng trung bình toàn bộ.
- Một số cột không cần thiết hoặc chứa quá nhiều giá trị thiếu (**Property ID**, **Download date / time**, **Property legal description**, **Settlement date**, **Property name**, **Strata lot number**) được loại bỏ khỏi tập dữ liệu.

```

1 df_domain[['Beds', 'Baths', 'Parking']] = df_domain[['Beds', 'Baths', 'Parking']]
  .fillna(0)
2 df_nsw[['Zoning', 'Area type']] = df_nsw[['Zoning', 'Area type']].fillna('
  unknown')
3
4 df_nsw['Area'] = df_nsw.groupby('Area type')['Area'].transform(
5     lambda x: x.fillna(x.mean())
6 )
7 df_nsw['Area'] = df_nsw['Area'].fillna(df_nsw['Area'].mean())
8
9 df_nsw = df_nsw.drop(columns=['Property ID', 'Download date / time',
10                             "Property legal description", "Settlement date",
11                             "Property name", "Strata lot number"])
12
13 median_size = df_domain.groupby(['Type', 'Beds'])['Size'].median().reset_index()
14 median_size = median_size.rename(columns={'Size': 'median_size'})
15 df_domain = df_domain.merge(median_size, on=['Type', 'Beds'], how='left')
16
17 df_domain['Size'] = np.where(df_domain['Size'].isna(), df_domain['median_size'],
18                             df_domain['Size'])
19
20 df_domain['Size'] = df_domain['Size'].fillna(df_domain['Size'].median())
21
22 df_domain = df_domain.drop(columns=['median_size'])

```

2.2.2 Loại bỏ bản ghi trùng lặp và không hợp lệ

```

1 df_domain = df_domain.drop_duplicates()
2 df_nsw = df_nsw.drop_duplicates()
3
4 df_domain = df_domain.dropna(subset=["Price", "postcode", "lat", "lon"])
5 df_nsw = df_nsw.dropna(subset=["Purchase price", "Property post code", "Contract
  date"])

```

2.2.3 Chuẩn hoá dữ liệu

Chuyển đổi kiểu dữ liệu số Các cột chứa thông tin giá bán được chuyển đổi sang kiểu số thực bằng hàm `pd.to_numeric()`.

```
1 df_domain["Price"] = pd.to_numeric(df_domain["Price"], errors="coerce")
2 df_nsw["Purchase price"] = pd.to_numeric(df_nsw["Purchase price"], errors="coerce")
```

Chuẩn hoá chuỗi ký tự Các cột chứa tên địa chỉ, tên đường, khu vực và tiểu bang được chuyển toàn bộ về dạng chữ thường, loại bỏ khoảng trắng dư thừa ở đầu và cuối chuỗi nhằm đồng nhất định dạng.

```
1 for col in ["Address", "street_name", "suburb", "state"]:
2     if col in df_domain.columns:
3         df_domain[col] = df_domain[col].astype(str).str.strip().str.lower()
4
5 for col in ["Property street name", "Property locality"]:
6     if col in df_nsw.columns:
7         df_nsw[col] = df_nsw[col].astype(str).str.strip().str.lower()
```

Chuẩn hoá tên đường Để đồng bộ cách viết tên đường giữa hai nguồn dữ liệu, một hàm `normalize_street_name()` được xây dựng nhằm:

- Viết thường toàn bộ tên đường và loại bỏ dấu câu.
- Chuẩn hoá các từ thông dụng theo quy tắc: road → rd, street → st, avenue → ave, drive → dr, v.v.
- Gộp các khoảng trắng dư thừa và xoá ký tự đặc biệt.

```
1 import re
2
3 def normalize_street_name(name: str):
4     if not isinstance(name, str):
5         return ""
6
7     name = name.lower().strip()
8
9     replacements = {
10         r'\broad\b': 'rd',
11         r'\bstreet\b': 'st',
```

```

12     r'\bavenue\b': 'ave',
13     r'\bplace\b': 'pl',
14     r'\bdrive\b': 'dr',
15     r'\bparade\b': 'pde',
16     r'\bhighway\b': 'hwy',
17     r'\bcrescent\b': 'cres',
18     r'\bclose\b': 'cl',
19     r'\blane\b': 'ln',
20     r'\bterrace\b': 'tce',
21     r'\bboulevard\b': 'blvd'
22 }
23
24 for pattern, repl in replacements.items():
25     name = re.sub(pattern, repl, name)
26
27     name = re.sub(r'[\w\s]', '', name)
28     name = re.sub(r'\s+', ' ', name).strip()
29
30     return name
31
32 df_domain["street_name"] = df_domain["street_name"].apply(normalize_street_name)
33 df_nsw["Property street name"] = df_nsw["Property street name"].apply(
    normalize_street_name)

```

2.2.4 Tạo đặc trưng mới

Sau khi dữ liệu được chuẩn hoá, tiến hành xây dựng thêm các đặc trưng mới giúp mô hình phân tích hoặc so sánh giá bất động sản hiệu quả hơn.

Khoảng cách đến trung tâm Sydney Tạo đặc trưng `dist_to_sydney` để đo khoảng cách từ mỗi bất động sản đến trung tâm thành phố Sydney (tọa độ $-33.8688, 151.2093$). Khoảng cách được tính bằng hàm `haversine()` dựa trên kinh độ (`lon`) và vĩ độ (`lat`) của từng bất động sản. Đặc trưng này giúp đánh giá ảnh hưởng của vị trí địa lý đến giá bán.

```

1 SYDNEY = (-33.8688, 151.2093)
2
3 df_domain["dist_to_sydney"] = haversine(

```

```
4 df_domain["lat"], df_domain["lon"],
5 SYDNEY[0], SYDNEY[1]
6 )
```

Giá trên mét vuông Để có cái nhìn chính xác hơn về giá trị thực của bất động sản, tạo thêm biến `price_per_m2` thể hiện giá trung bình trên một mét vuông diện tích. Đặc trưng này được tính riêng cho từng bộ dữ liệu:

```
1 df_domain['price_per_m2'] = df_domain['Price'] / df_domain['Size']
2 df_nsw['price_per_m2'] = df_nsw['Purchase price'] / df_nsw['Area']
```

2.2.5 Phát hiện và loại bỏ ngoại lệ

Phương pháp Isolation Forest *Isolation Forest* là thuật toán dựa trên nguyên lý cách ly các điểm dữ liệu thay vì mô hình hóa phân phối của chúng. Các điểm ngoại lệ thường dễ bị cô lập hơn trong cây nhị phân được xây dựng ngẫu nhiên — do đó, có độ sâu trung bình nhỏ hơn so với các điểm bình thường. Ưu điểm:

- Hiệu quả với dữ liệu có nhiều chiều (multivariate outlier detection).
- Không yêu cầu giả định phân phối chuẩn.
- Có khả năng mở rộng cho tập dữ liệu lớn.

Triển khai Hàm `detect_outliers()` được xây dựng để tự động phát hiện các điểm ngoại lệ trong tập dữ liệu. Trước khi đưa vào mô hình, dữ liệu được chuẩn hóa bằng `StandardScaler` và xử lý các giá trị vô hạn (`inf`) hoặc thiếu bằng trung vị của từng cột.

```
1 from sklearn.ensemble import IsolationForest
2 from sklearn.preprocessing import StandardScaler
3
4 def detect_outliers(df, features, sample_frac=1.0, random_state=42):
5     df = df.copy()
6
7     X = df[features].replace([np.inf, -np.inf], np.nan)
8     X = X.fillna(X.median())
9     X = np.clip(X, a_min=-1e9, a_max=1e9)
```



```

10
11     scaler = StandardScaler()
12     X_scaled = scaler.fit_transform(X)
13
14     if sample_frac < 1.0:
15         df_sample = df.sample(frac=sample_frac, random_state=random_state)
16         X_sample = scaler.transform(df_sample[features].replace([np.inf, -np.inf
17 ], np.nan).fillna(X.median()))
18     else:
19         df_sample = df
20         X_sample = X_scaled
21
22     iso = IsolationForest(
23         n_estimators=200,
24         contamination=0.02,
25         random_state=random_state,
26         max_samples='auto',
27         n_jobs=-1
28     )
29     iso.fit(X_sample)
30
31     preds = iso.predict(X_scaled)
32     df["is_outlier"] = preds == -1
33
34     return df

```

```

1 domain_features = ['Price', 'Beds', 'Baths', 'Parking',
2                     'Size', 'price_per_m2', 'lat', 'lon']
3 domain_clean = detect_outliers(df_domain, domain_features)
4 print("Domain outliers detected:", domain_clean["is_outlier"].sum())
5
6 nsw_features = ['Purchase price', 'Area', 'price_per_m2']
7 nsw_clean = detect_outliers(df_nsw, nsw_features, sample_frac=0.4)
8 print("NSW outliers detected:", nsw_clean["is_outlier"].sum())
9
10 df_domain = domain_clean[~domain_clean["is_outlier"]].drop(columns="is_outlier")
11 df_nsw = nsw_clean[~nsw_clean["is_outlier"]].drop(columns="is_outlier")

```

```
12  
13 print(f"Domain cleaned shape: {df_domain.shape}")  
14 print(f"NSW cleaned shape: {df_nsw.shape}")
```

Kết quả

- Bộ dữ liệu domain phát hiện **336 outlier** và còn lại **16,437** bản ghi hợp lệ.
- Bộ dữ liệu nsw phát hiện **31,673 outlier** và còn lại **1,553,001** bản ghi.

3 Phân tích dữ liệu với SQL

Mục báo cáo này sử dụng thư viện SQLite trong python để phân tích những yếu tố khác nhau sẽ ảnh hưởng thế nào đến giá của các bất động sản

Kết quả sẽ cung cấp cái nhìn sâu hơn về thị trường bất động sản ở Úc nói chung và bang New South Wales nói riêng

3.1 Phương pháp thực hiện

1. Thêm các thư viện cần thiết:

```
1 import pandas as pd
2 import sqlite3
```

Listing 1: Import Libraries

2. Đọc file csv

```
1 path = 'dataset/cleaned/domain.csv'
2 df = pd.read_csv(path)
3
4 path_nsw = 'dataset/cleaned/nsw.csv'
5 df_nsw = pd.read_csv(path_nsw)
```

Listing 2: Read CSV

3. Chuyển từng dataframe vào database tương ứng

```
1 conn = sqlite3.connect('AusPrice.db')
2 df.to_sql("AusPrice", conn, if_exists="replace", index=False)
3
4 conn_2 = sqlite3.connect('NSW.db')
5 df_nsw.to_sql("NSW", conn_2, if_exists="replace", index=False)
```

Listing 3: Connect SQL

3.2 Các truy vấn SQL

Mục tiêu: Cho ta thấy bang nào đang là đắt đỏ nhất. Từ đó cho thấy sự chênh lệch nhu cầu mua bất động sản ở các bang khác nhau

3.2.1 Thống kê mức giá trung bình của bất động sản theo từng bang

Mục tiêu: Xác định bang có mức giá bất động sản trung bình cao nhất, qua đó phản ánh sự chênh lệch nhu cầu và sức nóng thị trường giữa các khu vực.

Thực hiện:

```
1 query_avg_state = """
2     SELECT State, AVG(Price) as avg_price
3     FROM AusPrice
4     GROUP BY State
5     ORDER BY avg_price DESC
6 """
7 avg_state = pd.read_sql_query(query_avg_state, conn)
```

Listing 4: Tính giá trung bình theo bang

Kết quả:

Bảng 3: Ranking of states by average property value

State	Avg. Price (AUD)
NSW	1 187 995
QLD	876 433.6
VIC	792 265.3
ACT	726 397.0
WA	674 629.8
SA	596 833.3
TAS	537 844.2
NT	434 586.5

Kết luận: Bảng trên thể hiện xếp hạng các bang theo giá bất động sản trung bình, trong đó New South Wales (NSW) dẫn đầu với mức giá cao nhất. Các bang tiếp theo như Queensland (QLD) và Victoria (VIC) cũng duy trì mức giá tương đối cao, cho thấy sức nóng tập trung tại các khu vực đô thị lớn. Ngược lại, các bang ở nửa cuối bảng chẳng hạn South Australia (SA)

hay **Tasmania (TAS)** có giá trung bình thấp hơn, phản ánh sự phân hóa rõ rệt về cầu nhà ở giữa các vùng.

3.2.2 Thống kê số lượng của từng loại hình bất động sản theo bang NSW

Mục tiêu: Xác định loại hình bất động sản phổ biến nhất tại bang New South Wales (NSW), qua đó đánh giá xu hướng lựa chọn nhà ở và cơ cấu nhu cầu của người mua trong khu vực.

Thực hiện:

```
1 query_population_realestate = """
2 SELECT Type, COUNT(Type) AS count_type
3 FROM AusPrice
4 WHERE State = 'nsw'
5 GROUP BY Type
6 ORDER BY count_type DESC
7 """
8 population_realestate = pd.read_sql_query(query_population_realestate, conn)
```

Listing 5: Số lượng của từng loại hình bất động sản trong bang NSW

Kết quả:

Property Type	Count
Semi-detached	991
Terrace	827
Studio	724
Villa	714
Apartment / Unit / Flat	649
Duplex	584
New apartments / off the plan	563
New house and land	473
Townhouse	450
Vacant land	445
Retirement Living	433
New land	335
Block of units	260
Development site	182
New home designs	169
Penthouse	114

Kết luận: Các loại hình **Semi-detached**, **Terrace**, và **Studio** là phổ biến nhất tại bang **New South Wales (NSW)**, phản ánh xu hướng lựa chọn nhà riêng có diện tích nhỏ trong bối cảnh quỹ đất hạn chế. Sự hiện diện đáng kể của nhóm **Apartment / Unit / Flat** và các dự án **off the plan** cho thấy tốc độ đô thị hoá mạnh mẽ và nhu cầu đầu tư bất động sản gia tăng tại khu vực Sydney và lân cận. Thị trường NSW vì thế thể hiện sự kết hợp giữa *nhu cầu ở thực* và *động cơ đầu tư* - hai lực tác động song song định hình diện mạo bất động sản hiện nay.

3.2.3 Thống kê mức giá trung bình theo từng cấu hình bất động sản

Mục tiêu: Phân tích mối quan hệ giữa **số lượng phòng tắm, phòng ngủ và số chỗ đậu xe** với **giá trung bình của bất động sản**, nhằm xác định các đặc điểm cấu hình nhà ở có ảnh hưởng lớn nhất đến giá trị thị trường.

Thực hiện:

```
1 query_property_config = """
2 SELECT Beds, Baths, Parking, AVG(Price) AS avg_price
3 FROM AusPrice
4 GROUP BY Beds, Baths, Parking
5 ORDER BY avg_price DESC
6 LIMIT 10
7 """
8 property_config = pd.read_sql_query(query_property_config, conn)
```

Listing 6: Giá trung bình theo cấu hình bất động sản

Kết quả:

Beds	Baths	Parking	Average Price (AUD)
10	6	3	4,225,000
10	0	0	3,960,000
4	5	4	3,750,000
8	3	1	3,750,000
2	3	0	3,725,000
4	4	5	3,677,500
5	0	2	3,650,000
6	6	0	3,650,000
7	3	4	3,468,000
4	3	0	3,442,857

Kết luận: Các bất động sản có **nhiều phòng ngủ và phòng tắm** thường có giá trung bình cao hơn, đặc biệt là những cấu hình từ **4 phòng trở lên** đi kèm nhiều chỗ đậu xe. Điều này phản ánh xu hướng tăng giá theo *quy mô và tiện ích nhà ở*, cho thấy thị trường ưu tiên các bất động sản cao cấp, có không gian và tiện nghi vượt trội.

3.2.4 Thống kê số lượng bất động sản theo bang

Mục tiêu: Phân tích sự phân bố của bất động sản trên toàn nước Úc, nhằm xác định các bang có hoạt động mua bán nhà ở sôi động nhất, từ đó phản ánh mức độ phát triển và sức hút của từng khu vực trên thị trường bất động sản.

Thực hiện:

```
1 query_count_realestate = """
2 SELECT State, COUNT(Type) as Count
3 FROM AusPrice
4 GROUP By State
5 ORDER BY Count DESC
6 """
7 count_realestate = pd.read_sql_query(query_count_realestate, conn)
```

Listing 7: Số lượng bất động sản theo từng bang

Kết quả:

State	Count
NSW	7913
VIC	3682
QLD	2856
WA	862
ACT	448
SA	401
TAS	220
NT	55

Kết luận: Số lượng bất động sản tập trung nhiều nhất tại **New South Wales (NSW)** và **Victoria (VIC)**, cho thấy đây là hai thị trường chủ lực của Úc, nơi hoạt động giao dịch và phát triển nhà ở diễn ra mạnh mẽ nhất. Bang **Queensland (QLD)** cũng thể hiện sức tăng trưởng đáng

kể, đặc biệt ở khu vực ven biển. Ngược lại, các bang nhỏ như **Tasmania** hay **Northern Territory** có quy mô thị trường hạn chế, phản ánh mật độ dân cư thấp và mức độ đô thị hóa chưa cao.

Từ góc nhìn thị trường, xu hướng này cho thấy *thị trường bất động sản Úc mang tính tập trung cao*, với trọng tâm rõ rệt tại các trung tâm kinh tế lớn - nơi hội tụ việc làm, dân cư, và nhu cầu nhà ở bền vững nhất.

3.2.5 Thống kê biên độ giá theo từng loại hình bất động sản

Mục tiêu: Phân tích sự khác biệt về giá giữa các loại hình bất động sản trên thị trường Úc, nhằm xác định nhóm bất động sản có giá trị trung bình cao nhất và đánh giá mức độ chênh lệch giá trong từng phân khúc.

Thực hiện:

```

1 query_minmax_realestate = """
2 SELECT Type, MIN(Price) AS min_p, MAX(Price) AS max_p, AVG(Price) AS avg_p
3 FROM AusPrice
4 GROUP BY Type
5 ORDER BY avg_p DESC;
6 """
7 minmax_realestate = pd.read_sql_query(query_minmax_realestate, conn)

```

Listing 8: Biên độ giá theo loại hình bất động sản

Kết quả:

Type	Min (AUD)	Max (AUD)	Average (AUD)
Terrace	201,000	7,450,000	2,029,938
Penthouse	325,000	6,950,000	1,596,467
Semi-detached	160,000	7,000,000	1,455,645
Block of units	149,000	7,200,000	1,192,111
Development site	99,000	6,900,000	1,180,771
New apartments / off the plan	256,000	7,450,000	1,150,536
Duplex	148,000	4,500,000	1,142,365
New house and land	110,000	7,100,000	1,035,194
Townhouse	138,000	5,750,000	1,011,851
Villa	118,000	3,995,000	831,835
Apartment / Unit / Flat	109,000	5,450,000	816,827
New home designs	140,000	5,795,000	801,753
Retirement Living	105,000	3,400,000	605,801
Vacant land	95,000	6,000,000	574,710
New land	95,000	6,400,000	544,485
Studio	95,000	2,200,000	417,481

Kết luận: Các loại hình **Terrace** và **Penthouse** dẫn đầu với mức giá trung bình lần lượt khoảng 2.0 triệu và 1.6 triệu AUD, phản ánh phân khúc nhà ở cao cấp tập trung tại các khu vực trung tâm thành phố, nơi đất đai hạn chế và giá trị vị trí cao.

Nhóm **Semi-detached**, **Block of units** và **Development site** cũng có giá trung bình trên 1 triệu AUD, cho thấy sự cạnh tranh giữa các mô hình nhà liền kề và bất động sản phát triển mới.

Trong khi đó, các loại hình như **Studio**, **Vacant land** hay **Retirement Living** có giá trung bình thấp hơn đáng kể, phản ánh phân khúc thị trường hướng đến đối tượng đầu tư nhỏ lẻ hoặc người mua có nhu cầu nhà ở cơ bản.

Từ góc nhìn toàn cảnh, *thị trường bất động sản Úc thể hiện sự phân tầng rõ rệt theo loại hình*, với biên độ giá trải dài từ khoảng **95,000 AUD** đến hơn **7 triệu AUD**, cho thấy mức độ đa dạng và phức tạp trong cấu trúc giá nhà ở - vừa mở ra cơ hội đầu tư linh hoạt, vừa khẳng định sức hút của phân khúc cao cấp tại các đô thị lớn.

3.2.6 Thống kê mức giá bất động sản trung bình theo khu vực

Mục tiêu: Xác định những **suburb** (khu vực dân cư) có giá bất động sản trung bình cao nhất tại Úc, nhằm phản ánh sự tập trung của phân khúc cao cấp và đánh giá xu hướng phát triển đô thị theo khu vực.

Thực hiện:

```

1 query_highest_suburb = """
2 SELECT suburb, AVG(price) as mean_price
3 FROM AusPrice
4 GROUP BY suburb
5 ORDER BY mean_price DESC
6 LIMIT 10
7 """
8 highest_suburb = pd.read_sql_query(query_highest_suburb, conn)

```

Listing 9: Top 10 suburb có giá bất động sản trung bình cao nhất

Kết quả:

Suburb	Average Price (AUD)
Lane Cove West	6,900,000
Tyabb	6,400,000
East Killara	5,594,444
Newrybar	4,900,000
Lavender Bay	4,850,000
Bellevue Hill	4,832,750
Cotton Tree	4,600,000
Barangaroo	4,600,000
Cabarita	4,585,000
Millers Point	4,409,000

Kết luận: Danh sách cho thấy các khu vực có giá bất động sản trung bình cao nhất đều nằm trong hoặc gần các trung tâm đô thị lớn, đặc biệt là **Sydney** và **Melbourne** — nơi tập trung các suburb như **Lane Cove West**, **Bellevue Hill**, và **Lavender Bay**. Những khu vực này thường sở hữu vị trí chiến lược gần trung tâm kinh tế, cảnh quan ven sông hoặc ven biển, và cơ sở hạ tầng đồng bộ, khiến giá trị nhà ở được duy trì ở mức cao ổn định.

Đáng chú ý, sự xuất hiện của **Tyabb** (một vùng ngoại ô của Victoria) và **Newrybar** (ở New South Wales) cho thấy xu hướng lan tỏa giá cao ra ngoài khu vực trung tâm - phản ánh nhu cầu sở hữu bất động sản rộng rãi, kết hợp không gian sống cao cấp và môi trường tự nhiên yên tĩnh.

Tổng thể, dữ liệu khẳng định rằng *phân khúc cao cấp tại Úc vẫn duy trì sự tập trung mạnh ở vùng đô thị giàu có, song đang dần mở rộng về hướng ngoại ô và ven biển*, nơi vừa đáp ứng chất lượng sống, vừa duy trì giá trị đầu tư lâu dài.

3.2.7 Thống kê các tuyến đường theo mức giá bất động sản trung bình tại NSW

Mục tiêu: Xác định các tuyến đường có **giá trung bình bất động sản cao nhất** tại bang **New South Wales (NSW)**, nhằm nhận diện các khu vực tập trung nhiều tài sản giá trị cao và phản ánh sự phân tầng trong thị trường nhà ở cao cấp.

Thực hiện:

```
1 query_highest_st = """
2 SELECT "Property street name", AVG("Purchase price") AS avg_price
3 FROM NSW
4 GROUP BY "Property street name"
5 ORDER BY avg_price DESC
6 LIMIT 10;
7 """
8 highest_st = pd.read_sql_query(query_highest_st, conn_2)
```

Listing 10: Các tuyến đường có giá trung bình cao nhất tại NSW

Kết quả:

Property street name	Average Price (AUD)
mount adelaide st	15,000,000
northcliff st level 5	13,200,000
barrow rd	12,250,000
exell st	11,250,000
farrow rd	11,143,000
lockwood rd	11,110,000
wybalena rd rd	11,000,000
campbell ln	11,000,000
hexham pl	10,900,000
yanada rd	10,464,000

Kết luận: Giá bất động sản tập trung mạnh tại một số tuyến đường đặc biệt đắt đỏ ở bang **New South Wales (NSW)**, phản ánh mức độ tập trung tài sản cao và sự phân tầng rõ nét của thị trường. Những khu vực này chủ yếu nằm gần trung tâm hoặc ven biển Sydney, thể hiện đặc trưng của *thị trường bất động sản hạng sang* tại Úc, nơi vị trí địa lý đóng vai trò quyết định đối với giá trị tài sản.

3.2.8 Thống kê các tháng có giá trung bình cao nhất tại NSW

Mục tiêu: Xác định những tháng có giá trung bình cao nhất tại bang New South Wales (NSW) trong giai đoạn hiện đại (sau năm 1999). Mục tiêu nhằm nhận diện các *đỉnh giá cục bộ* của thị trường trong hơn hai thập kỷ qua, từ đó giúp hiểu rõ chu kỳ tăng trưởng và biến động giá bất động sản tại Sydney.

Thực hiện:

```

1 query_avg_monthly = ""
2 SELECT strftime('%Y-%m', "Contract date") AS month, AVG("Purchase price") AS
   avg_price
3 FROM NSW
4 WHERE CAST(strftime('%Y', "Contract date") AS INTEGER) > 1999
5 GROUP BY month
6 ORDER BY avg_price DESC
7 LIMIT 10
8 ""
9 avg_monthly = pd.read_sql_query(query_avg_monthly, conn_2)

```

Listing 11: Các tháng có giá trung bình cao nhất tại NSW sau năm 1999

Kết quả:

Month	Average Price (AUD)
2006-11	2,398,857
2000-05	2,222,000
2004-12	2,174,000
2010-07	2,018,641
2001-11	1,823,240
2000-08	1,685,000
2000-11	1,439,250
2003-01	1,400,000
2009-11	1,397,324
2008-03	1,385,000

Kết luận: Các tháng như 11/2006, 12/2004 và 05/2000 ghi nhận mức giá trung bình cao nhất trong hơn 20 năm qua, đánh dấu những giai đoạn *sôi động của thị trường bất động sản NSW*. Đặc biệt, **giai đoạn 2000–2006** thể hiện sự tăng mạnh của giá nhà nhờ chính sách tín dụng nới lỏng và dòng vốn đầu tư ngoại quốc. Sau khủng hoảng tài chính 2008, thị trường phục hồi dần

và đạt lại đỉnh vào **2010**, phản ánh chu kỳ tái tăng trưởng sau giai đoạn điều chỉnh. Tổng thể, dữ liệu cho thấy *giá trung bình tại NSW duy trì xu hướng tăng theo từng chu kỳ 5-7 năm*, thể hiện bản chất **ổn định nhưng chu kỳ hoá mạnh** của thị trường bất động sản Sydney.

3.2.9 Thống kê các tháng có số lượng giao dịch cao nhất tại NSW

Mục tiêu: Xác định các tháng có **số lượng giao dịch bất động sản cao nhất** tại bang **New South Wales (NSW)** trong giai đoạn hiện đại (sau năm 1999), nhằm phân tích *mức độ thanh khoản và tâm lý thị trường* qua từng chu kỳ.

Thực hiện:

```

1 query_number_sale_per_month = """
2 SELECT
3     strftime('%Y-%m', "Contract date") AS month,
4     COUNT(*) AS total_sales
5 FROM NSW
6 WHERE CAST(strftime('%Y', "Contract date") AS INTEGER) > 1999
7 GROUP BY month
8 ORDER BY total_sales DESC
9 LIMIT 10
10 """
11 number_sale_per_month = pd.read_sql_query(query_number_sale_per_month, conn_2)

```

Listing 12: Các tháng có số lượng giao dịch cao nhất tại NSW sau năm 1999

Kết quả:

Month	Total Sales
2025-05	27,739
2021-03	27,207
2021-11	23,046
2021-05	22,696
2021-06	21,798
2025-06	21,600
2021-07	21,578
2021-10	21,498
2020-11	21,363
2020-12	21,117

Kết luận: Các tháng có khối lượng giao dịch cao nhất tập trung chủ yếu trong **giai đoạn**

2020–2025, đặc biệt là năm **2021** - giai đoạn phục hồi mạnh mẽ sau đại dịch COVID-19, được hỗ trợ bởi *lãi suất thấp kỷ lục và chính sách kích thích kinh tế*. Điều này cho thấy mức **thanh khoản thị trường NSW** đạt đỉnh trong bối cảnh người dân chuyển hướng đầu tư vào tài sản thực.

Khi đối chiếu với phần trước (Bảng 3.2.8), ta thấy rằng **đỉnh thanh khoản không trùng với đỉnh giá trung bình**. Những tháng có khối lượng giao dịch cao (2021–2025) không phải là các tháng có giá trung bình cao nhất (2000–2006). Điều này phản ánh *hai chu kỳ khác nhau của thị trường*: chu kỳ đầu (2000–2006) là **giai đoạn tăng giá mạnh**, còn chu kỳ sau (2020–2025) là **giai đoạn giao dịch sôi động nhờ thanh khoản và tín dụng mở rộng**. Tổng thể, dữ liệu khẳng định rằng **đỉnh giá và đỉnh thanh khoản thường lệch pha nhau**, và cần được xem xét đồng thời để đánh giá đúng chu kỳ vận hành của thị trường bất động sản NSW.

3.2.10 Thống kê tổng giá trị giao dịch bất động sản theo mã vùng tại NSW

Mục tiêu: Xác định các mã vùng (postcode) có **tổng giá trị mua bán bất động sản cao nhất** tại bang **New South Wales (NSW)**, nhằm nhận diện các khu vực tập trung tài sản lớn và hoạt động giao dịch mạnh, từ đó phản ánh mức độ phát triển của từng vùng trong thị trường nhà ở.

Thực hiện:

```

1 query_pos_totalsale = """
2 SELECT "Property post code", SUM("Purchase price") AS total_value
3 FROM NSW
4 GROUP BY "Property post code"
5 ORDER BY total_value DESC
6 LIMIT 10;
7 """
8 pos_totalsale = pd.read_sql_query(query_pos_totalsale, conn_2)
9 print(pos_totalsale)

```

Listing 13: Các mã vùng có tổng giá trị giao dịch bất động sản cao nhất tại NSW

Kết quả:

Property Postcode	Total Sales Value (AUD)
2765	25,074,459,017
2112	22,977,785,468
2155	20,710,713,293
2000	20,629,811,057
2065	14,641,519,422
2170	13,917,188,273
2088	13,592,765,736
2570	13,186,651,506
2026	12,935,763,405
2230	12,905,013,514

Kết luận: Các mã vùng như **2765** (Marsden Park), **2112** (Ryde) và **2155** (Kellyville–Rouse Hill) dẫn đầu về tổng giá trị giao dịch, cho thấy mức độ phát triển đô thị và nhu cầu nhà ở cao tại các khu vực này. Khu vực trung tâm như **2000** (Sydney CBD) cũng góp mặt trong nhóm dẫn đầu, phản ánh vai trò kinh tế cốt lõi của vùng trung tâm tài chính. Nhìn chung, dữ liệu cho thấy thị trường NSW tập trung giá trị tài sản lớn quanh *vành đai đô thị Sydney*, nơi kết hợp giữa khu dân cư cao cấp, hạ tầng phát triển và sức mua ổn định.

4 Phân tích dữ liệu với Pandas

Phần này sử dụng thư viện **Pandas** trong Python để xử lý, thống kê và phân tích dữ liệu bất động sản. Khác với SQLite, Pandas cho phép thao tác trực tiếp trên **DataFrame**, giúp việc làm sạch dữ liệu, nhóm (grouping), và tính toán thống kê (như trung bình, phương sai, hoặc mật độ giá) trở nên linh hoạt và nhanh chóng hơn.

Thông qua các phép truy vấn, lọc dữ liệu, và tính toán trong Pandas, báo cáo sẽ khai thác sâu các đặc trưng như **giá trung bình**, **mật độ giao dịch**, **giá trên mỗi mét vuông**, từ đó cung cấp cái nhìn rõ nét hơn về **cấu trúc**, **xu hướng** và **mức độ phân hoá** của thị trường bất động sản Úc - đặc biệt là tại bang **New South Wales (NSW)**.

4.1 Phương pháp thực hiện

1. Thêm các thư viện cần thiết:

```
1 import pandas as pd
```

Listing 14: Import Libraries

2. Đọc file csv

```
1 path = 'dataset/cleaned/domain.csv'
2 df = pd.read_csv(path)
3
4 path_nsw = 'dataset/cleaned/nsw.csv'
5 df_nsw = pd.read_csv(path_nsw)
```

Listing 15: Read CSV

4.2 Các phân tích với Pandas

Mục tiêu: Cho ta thấy bang nào đang là đắt đỏ nhất. Từ đó cho thấy sự chênh lệch nhu cầu mua bất động sản ở các bang khác nhau

4.2.1 Thống kê giá trung bình trên mỗi mét vuông theo khu vực tại NSW

Mục tiêu: Xác định các khu vực (locality) có giá bất động sản trung bình trên mỗi mét vuông cao nhất tại bang New South Wales (NSW), nhằm phản ánh mật độ giá trị đất đai, sức hút đầu tư và mức độ đắt đỏ thực tế giữa các vùng trung tâm đô thị.

Thực hiện:

```
1 pricem2_per_suburb = df_nsw.groupby('Property locality')['price_per_m2'].mean().
   sort_values(ascending=False).head(10)
```

Listing 16: Các khu vực theo giá trung bình trên mỗi mét vuông cao nhất tại NSW

Kết quả:

Property Locality	Average Price per m ² (AUD)
kings cross	47,777.78
barangaroo	27,096.62
the rocks	22,236.34
paddington	20,983.46
sydney	20,366.71
darlinghurst	19,847.11
lavender bay	18,938.09
elizabeth bay	18,585.92
mcmahons point	17,905.06
surry hills	17,852.78

Kết luận: Các khu vực như **Kings Cross**, **Barangaroo** và **The Rocks** dẫn đầu về giá trung bình trên mỗi mét vuông, phản ánh đặc trưng của các khu trung tâm đô thị cũ, nơi quỹ đất hạn chế và mật độ thương mại cao đẩy giá lên mức rất cao. Khu vực **Sydney CBD** và vùng phụ cận như **Darlinghurst**, **Surry Hills** cũng duy trì giá trị đất cao, thể hiện *sức hấp dẫn bền vững* của khu trung tâm, nơi hội tụ hoạt động kinh tế, thương mại và văn hoá của bang NSW.

4.2.2 Thống kê các tuyến đường theo số lượng giao dịch bất động sản tại NSW

Mục tiêu: Phân tích mức độ sôi động của thị trường thông qua số lượng giao dịch bất động sản trên từng tuyến đường. Kết quả giúp xác định các khu vực có **mật độ mua bán cao**, thường là những nơi có hạ tầng phát triển, dân cư đông hoặc tập trung nhiều dự án nhà ở.

Thực hiện:

```
1 df_nsw.groupby('Property street name').size()
2   .sort_values(ascending=False).head(10)
```

Listing 17: Các tuyến đường có số lượng giao dịch nhiều nhất tại NSW

Kết quả:

Property Street Name	Number of Transactions
nancarrow ave	15,638
pacific hwy	7,854
george st	7,842
pitt st	6,744
gladstone st	6,075
princes hwy	4,371
church st	4,091
king st	3,452
victoria st	3,396
william st	3,240

Kết luận: Các tuyến đường như **Nancarrow Avenue**, **Pacific Highway** và **George Street** ghi nhận số lượng giao dịch cao nhất tại bang **New South Wales (NSW)**. Điều này phản ánh vai trò trung tâm của các khu vực này trong hoạt động mua bán và phát triển nhà ở, đặc biệt là tại những trục giao thông chính và khu vực tái quy hoạch đô thị. Xu hướng cho thấy *giao dịch tập trung mạnh tại các hành lang kinh tế và vùng đô thị ven trung tâm Sydney*, thể hiện tính sôi động và mức cầu cao của thị trường bất động sản khu vực này.

4.2.3 Thống kê mã vùng theo mức giá trung bình NSW

Mục tiêu: Xác định các mã vùng (postcode) có giá trung bình bất động sản cao nhất tại bang **New South Wales (NSW)**, nhằm nhận diện các khu vực có mức sống cao, mật độ tài sản lớn và thị trường tập trung vào phân khúc cao cấp.

Thực hiện:

```
1 df_nsw.groupby('Property post code')['Purchase price']
2   .mean().sort_values(ascending=False).head(10)
```

Listing 18: Các mã vùng có giá trung bình cao nhất tại NSW

Kết quả:

Property Postcode	Average Price (AUD)
2555	7,042,619
2556	4,063,826
2748	3,548,478
2108	3,452,318
2063	3,434,728
2030	3,413,127
2092	3,260,379
2104	3,245,601
2110	3,112,238
2175	3,110,158

Kết luận: Các mã vùng như **2555** (Bringelly), **2556** (Leppington) và **2748** (Luddenham) ghi nhận mức giá trung bình cao nhất, cho thấy sự nổi lên của các khu vực *ngoại ô cao cấp và vùng mở rộng đô thị*. Bên cạnh đó, các khu ven biển như **2108** (Whale Beach) và **2030** (Vaucluse) vẫn duy trì vị thế là những khu dân cư đắt đỏ nhất Sydney, thể hiện sự *phân hoá rõ rệt giữa khu nội đô ven biển và vùng phát triển mới*. Dữ liệu cho thấy thị trường NSW hiện có hai cực chính: *khu ven biển lâu đời và khu ngoại ô mở rộng* - đều tập trung tài sản giá trị cao.

4.2.4 Phân tích mối quan hệ giữa số lần giao dịch và giá bất động sản tại NSW

Mục tiêu: Khám phá mối quan hệ giữa **số lần giao dịch (Sale Counter)** và **giá trị bất động sản trung bình** tại bang **New South Wales (NSW)**. Mục tiêu là xác định xem những bất động sản được giao dịch nhiều lần có xu hướng tăng giá qua thời gian hay không, từ đó phản ánh *động lực đầu tư, tính thanh khoản và kỳ vọng giá của thị trường*.

Thực hiện:

```
1 df_nsw.groupby('Sale counter')['Purchase price']
2   .agg(['mean', 'median', 'count']).head(10).reset_index()
```

Listing 19: Mối quan hệ giữa số lần giao dịch và giá bất động sản tại NSW

Kết quả:

Sale Counter	Mean (AUD)	Median (AUD)	Count
1	780,606.65	550,000	46,479
2	779,720.79	550,000	44,265
3	809,471.65	565,000	41,984
4	827,236.56	585,000	39,564
5	860,863.56	607,500	37,268
6	880,415.86	626,000	35,156
7	905,025.11	649,000	33,308
8	921,829.51	658,500	31,708
9	950,203.91	676,000	30,253
10	968,498.44	685,000	29,008

Kết luận: Kết quả cho thấy xu hướng **giá trung bình và giá trung vị đều tăng dần theo số lần giao dịch**. Các bất động sản được giao dịch nhiều (từ 5–10 lần) có mức giá trung bình cao hơn khoảng **20–25%** so với nhóm giao dịch ít, phản ánh *sức cầu mạnh và giá trị tích lũy* trong quá trình chuyển nhượng. Đồng thời, sự gia tăng đều đặn của **median** cho thấy xu hướng này không chỉ do vài giao dịch bất thường mà mang tính hệ thống. Điều này khẳng định rằng **thị trường NSW có tính đầu tư và khả năng sinh lợi cao**, với các tài sản được trao tay nhiều lần thường nằm ở khu vực có tiềm năng tăng giá bền vững.

4.2.5 Phân tích tốc độ biến động giá trung bình theo tháng tại NSW

Mục tiêu: Đo lường **tốc độ thay đổi giá bất động sản theo tháng** tại bang New South Wales (NSW) dựa trên chỉ số **median price per m²**. Chỉ số này giúp phản ánh *nhịp dao động thực* của thị trường, giảm nhiễu so với giá trung bình (mean) và cho thấy giai đoạn nào giá tăng mạnh hoặc giảm sâu trong ngắn hạn.

Thực hiện:

```

1 dfa = df_nsw.copy()
2 dfa['Contract date'] = pd.to_datetime(df_nsw['Contract date'], errors='coerce')
3 dfa = dfa.dropna(subset=['Contract date', 'price_per_m2'])
4 dfa = dfa.sort_values('Contract date').set_index('Contract date')
5 mean_change = dfa['price_per_m2'].resample('M').median().pct_change() * 100
6 mean_change.sort_index(ascending=False).head(10)

```

Listing 20: Tính tốc độ thay đổi theo tháng của giá trung vị (price per m²)

Kết quả:

Month	Median Price Change (%)
2025-08	-27.25
2025-07	-12.12
2025-06	-9.73
2025-05	-3.31
2025-04	-2.02
2025-03	8.20
2025-02	18.20
2025-01	-2.90
2024-12	-15.78
2024-11	2.20

Kết luận: Thị trường bất động sản NSW trong giai đoạn gần đây cho thấy **sự sụt giảm rõ rệt từ tháng 4 đến tháng 8/2025**, đặc biệt tháng **8/2025 giảm tới hơn 27%** so với tháng trước. Ngược lại, **tháng 2–3/2025** ghi nhận mức tăng mạnh, phản ánh giai đoạn phục hồi hoặc dòng vốn đầu tư ngắn hạn. Xu hướng này cho thấy thị trường đang trong *chu kỳ điều chỉnh sau giai đoạn tăng nóng*, với biên độ biến động ngày càng lớn - dấu hiệu của **sự nhạy cảm với lãi suất và chính sách tín dụng**. Tuy nhiên, việc giảm sâu sau tháng 6 có thể mở ra **cơ hội mua vào** khi giá chạm vùng điều chỉnh tự nhiên của chu kỳ.

4.2.6 So sánh giá trung bình theo loại hình bất động sản giữa các bang tại Úc

Mục tiêu: Phân tích sự khác biệt về **giá trung bình bất động sản** giữa các loại hình (Type) và các **bang (State)** tại Úc. Qua đó nhận diện những loại hình và khu vực có giá trị cao, phản ánh *phân tầng thị trường* và xu hướng phát triển nhà ở theo vùng địa lý.

Thực hiện:

```

1 price_of_type_in_state = df.pivot_table(
2     values='Price',
3     index='Type',
4     columns='state',
5     aggfunc='mean',
6     margins=True,
7     margins_name='Total '
8 )
9 print(price_of_type_in_state)

```

Listing 21: Giá trung bình của từng loại hình bất động sản theo bang

Kết quả:

Type	ACT	NSW	NT	QLD	SA	TAS	VIC	WA	Total
Apartment / Unit / Flat	573,086	905,178	342,251	1,029,890	638,738	558,778	681,206	707,588	816,828
Block of units	NaN	1,533,033	341,875	1,032,023	971,023	881,000	933,826	1,241,152	1,192,111
Development site	820,000	1,462,226	455,000	1,074,584	474,743	430,286	1,209,996	682,827	1,180,771
Duplex	1,205,333	1,388,329	509,000	958,407	324,005	576,567	1,281,619	671,827	1,142,365
New apartments / off the plan	662,420	1,169,479	477,500	1,368,529	785,063	3,650,000	1,392,051	932,276	1,150,536
New home designs	NaN	902,890	NaN	929,356	1,096,441	834,525	744,135	985,300	801,753
New house and land	1,236,143	1,219,694	742,500	943,249	1,085,194	650,215	872,308	879,678	1,035,194
New land	679,833	737,549	NaN	439,237	280,733	273,125	473,199	433,548	544,485
Penthouse	1,172,625	1,762,315	NaN	1,665,091	917,321	1,152,500	1,083,450	1,476,500	1,596,467
Retirement Living	380,000	627,585	NaN	605,342	454,571	539,800	582,213	550,996	605,802
Semi-detached	944,200	1,609,251	521,107	957,028	477,600	NaN	979,000	630,036	1,455,645
Studio	264,188	496,031	158,167	268,045	314,010	369,357	238,419	310,750	417,481
Terrace	860,427	2,212,212	NaN	870,769	818,500	1,133,750	993,000	840,000	2,029,938
Townhouse	806,683	1,162,447	515,833	866,711	864,200	866,000	1,020,761	762,115	1,011,851
Vacant land	613,500	682,164	240,000	538,166	366,676	331,225	587,250	475,207	574,710
Villa	925,000	868,266	529,000	1,076,184	471,408	594,365	742,649	680,571	831,835
Total	726,397	1,187,995	434,586	876,434	596,833	537,844	792,265	674,630	980,065

Kết luận: Bảng so sánh cho thấy **New South Wales (NSW)** và **Queensland (QLD)** dẫn đầu về giá trung bình ở hầu hết các loại hình, đặc biệt là các dòng sản phẩm cao cấp như **Penthouse**, **Terrace** và **Semi-detached**. Các bang như **Tasmania (TAS)** và **Northern Territory (NT)** có giá thấp hơn đáng kể, phản ánh *mức cầu và mật độ dân cư thấp*. Sự chênh lệch rõ rệt giữa NSW và các bang nhỏ cho thấy thị trường Úc mang đặc trưng **phân tầng khu vực mạnh**, với *giá trị tập trung quanh các trung tâm kinh tế lớn* – nơi kết hợp giữa nhu cầu ở thực, đầu tư và thương mại.

4.2.7 Thống kê tỷ lệ bất động sản có chỗ đậu xe theo bang tại Úc

Mục tiêu: Đánh giá **tỷ lệ nhà ở có chỗ đậu xe** giữa các bang tại Úc, nhằm phản ánh sự khác biệt về *cấu trúc hạ tầng nhà ở, mật độ đô thị và thói quen sử dụng phương tiện cá nhân*. Chỉ số này thể hiện mức độ tiện nghi và quy mô phát triển của từng khu vực.

Thực hiện:

```

1 df.assign(has_parking = df['Parking'] > 0)
2   .groupby('state')['has_parking']
3   .mean().sort_values(ascending=False)

```

Listing 22: Tỷ lệ bất động sản có chỗ đậu xe theo bang

Kết quả:

State	Proportion of Properties with Parking (%)
ACT	90.18
NT	85.45
QLD	77.38
NSW	75.23
VIC	74.66
WA	67.87
SA	60.10
TAS	55.45

Kết luận: Các bang như **ACT** và **Northern Territory (NT)** có tỷ lệ nhà có chỗ đậu xe cao nhất (trên 85%), phản ánh đặc trưng đô thị thấp tầng và mật độ dân cư thấp — nơi xe hơi là phương tiện chính yếu. Trong khi đó, các bang như **Tasmania** và **South Australia** có tỷ lệ thấp hơn đáng kể, cho thấy xu hướng nhà nhỏ, khu trung tâm hoá hoặc hạ tầng hạn chế chỗ đậu. Nhìn chung, dữ liệu thể hiện rõ *sự tương phản giữa khu đô thị nén và khu dân cư ngoại ô*, và nhấn mạnh rằng tiện ích đậu xe vẫn là một yếu tố giá trị quan trọng trong bất động sản Úc.

4.2.8 Phân tích ảnh hưởng của chỗ đậu xe đến giá trị bất động sản theo từng bang

Mục tiêu: Phân tích sự khác biệt về giá trung bình bất động sản giữa hai nhóm nhà - có chỗ đậu xe (`has_parking=True`) và không có (`has_parking=False`) - trên toàn bộ các bang tại Úc. Kết quả giúp kiểm chứng rằng *chỗ đậu xe là một yếu tố làm tăng giá trị tài sản*, đồng thời mở rộng kết quả từ phần phân tích tỷ lệ nhà có chỗ đậu xe ở trên.

Thực hiện:

```

1 df['has_parking'] = df['Parking'] > 0
2 df.pivot_table(
3     index='state',
4     columns='has_parking',
5     values='Price',
6     aggfunc='mean'
7 )

```

Listing 23: So sánh giá trung bình giữa nhà có và không có chỗ đậu xe theo bang

Kết quả:

State	No Parking (AUD)	Has Parking (AUD)
ACT	527,483	748,061
NSW	1,047,989	1,234,091
NT	382,250	443,495
QLD	535,087	976,212
SA	343,581	764,967
TAS	328,419	706,071
VIC	570,499	867,532
WA	528,914	743,627

Kết luận: Ở tất cả các bang, giá trung bình của bất động sản có chỗ đậu xe luôn cao hơn đáng kể so với nhóm không có. Chênh lệch này đặc biệt lớn tại **Queensland (QLD)** và **South Australia (SA)**, nơi nhà có chỗ đậu xe đắt hơn lần lượt gần **82%** và **120%**. Tại các bang đô thị như **New South Wales (NSW)** và **Victoria (VIC)**, khoảng cách vẫn duy trì quanh mức **20–30%**, phản ánh *giá trị tiện ích của parking trong bối cảnh đất đô thị khan hiếm*. Khi đối chiếu với phần phân tích tỷ lệ nhà có parking ở trên, có thể thấy rằng **những bang có tỷ lệ sở hữu parking cao cũng là nơi parking mang lại giá trị tài sản cao**, khẳng định đây là *yếu tố cấu trúc quan trọng trong định giá bất động sản tại Úc*.

4.2.9 Phân tích độ biến động giá (rủi ro tương đối) theo loại hình và bang

Mục tiêu: Đánh giá mức độ biến động giá tương đối của các loại hình bất động sản giữa các bang tại Úc. Chỉ số được sử dụng là **hệ số biến thiên (Coefficient of Variation = std/mean)**, giúp phản ánh *độ rủi ro về giá* — tức là mức độ giá dao động mạnh hay ổn định quanh giá trung bình. Kết quả cho phép xác định những phân khúc thị trường có biên độ rủi ro cao nhất.

Thực hiện:

```

1 df.pivot_table(
2     values='Price',
3     index='state',
4     columns='Type',
5     aggfunc=lambda x: x.std() / x.mean()
6 )

```

Listing 24: Hệ số biến thiên của giá theo loại hình và bang

Kết quả:

State	Apartment	Block of Units	Development Site	Duplex	Off the Plan	New Land	Terrace	Vacant Land
ACT	0.341	NaN	0.370	0.352	0.503	0.221	0.304	0.130
NSW	0.553	0.761	0.925	0.513	0.827	0.788	0.513	0.875
NT	0.352	0.213	0.145	0.300	0.170	NaN	NaN	NaN
QLD	0.639	0.703	0.792	0.493	0.832	0.842	0.594	1.083
SA	0.431	0.560	0.833	0.285	0.493	0.551	0.452	0.999
TAS	0.402	0.559	0.784	0.311	NaN	0.557	0.688	0.471
VIC	0.632	0.537	0.852	0.983	0.792	1.263	0.731	0.968
WA	0.510	0.849	0.680	0.254	0.767	0.537	0.734	0.735

Kết luận: Kết quả cho thấy mức **biến động giá cao nhất** tập trung ở các loại hình như **Development site**, **New land**, và **Vacant land** — phản ánh tính đầu cơ và phụ thuộc quy hoạch. Ngược lại, các loại hình như **Duplex**, **Apartment**, và **Semi-detached** có độ ổn định cao hơn, thường gắn với nhu cầu ở thực. Giữa các bang, **New South Wales (NSW)** và **Victoria (VIC)** thể hiện mức biến động cao nhất ở nhiều phân khúc, cho thấy thị trường năng động nhưng cũng tiềm ẩn rủi ro đầu tư ngắn hạn. Trong khi đó, **ACT** và **NT** có hệ số biến thiên thấp, phản ánh thị trường nhỏ, ổn định hơn và ít chịu tác động bởi đầu cơ. Nhìn tổng thể, dữ liệu chứng minh sự phân hoá rõ rệt giữa thị trường phát triển mạnh (rủi ro cao) và thị trường dân cư ổn định (rủi ro thấp).

4.2.10 Thống kê loại hình bất động sản chiếm ưu thế tại các khu vực suburb

Mục tiêu: Xác định loại hình bất động sản chiếm ưu thế (**dominant type**) ở từng suburb và tìm ra **top 10 khu vực có số lượng giao dịch cao nhất** trong loại hình dẫn đầu đó. Kết quả giúp hiểu rõ đặc trưng phát triển của từng khu vực — khu nào thiên về nhà cổ kiểu terrace, khu nào tập trung căn hộ mới hay dự án đất nền.

Thực hiện:

```

1 counts = df.groupby(['suburb', 'Type']).size().unstack(fill_value=0)
2 dominant_type = counts.idxmax(axis=1)
3 dominant_count = counts.max(axis=1)
4 top10 = dominant_count.sort_values(ascending=False).head(10)
5 top10_df = pd.DataFrame({
6     'Dominant_Type': dominant_type[top10.index],
7     'Count': top10
8 })
9 print(top10_df)

```

Listing 25: Xác định loại hình bất động sản chiếm ưu thế ở từng suburb

Kết quả:

Suburb	Dominant Type	Count
Paddington	Terrace	154
Surry Hills	Terrace	83
Darlinghurst	Terrace	61
Potts Point	Studio	59
Elizabeth Bay	Studio	57
Melbourne	Studio	54
Schofields	New apartments / off the plan	48
Shell Cove	New land	47
Newcastle	New apartments / off the plan	41
Phillip	New apartments / off the plan	40

Kết luận: Kết quả cho thấy khu vực nội đô Sydney như **Paddington, Surry Hills, Darlinghurst** vẫn giữ đặc trưng kiến trúc cổ điển với loại hình **Terrace house** chiếm ưu thế tuyệt đối. Trong khi đó, các khu cận đô như **Schofields, Newcastle**, và **Phillip** đang bùng nổ với dòng sản phẩm **New apartments / off the plan** — biểu hiện của giai đoạn phát triển mới. Đáng chú ý, các khu ven biển như **Shell Cove** lại dẫn đầu ở mảng **New land**, phản ánh xu hướng mở rộng quỹ đất dân cư. Tổng thể, dữ liệu cho thấy thị trường bất động sản Úc mang tính **phân vùng rõ rệt**: khu trung tâm duy trì nét di sản, còn vùng ven đô hướng đến phát triển mới và hiện đại hoá.

5 Trực quan hóa dữ liệu với Python


Mục báo cáo này sử dụng thư viện SQLite trong python để phân tích những yếu tố khác nhau sẽ ảnh hưởng thế nào đến giá của các bất động sản

Kết quả sẽ cung cấp cái nhìn sâu hơn về thị trường bất động sản ở Úc nói chung và bang New South Wales nói riêng

5.1 Bản đồ nhiệt phân bố giá bất động sản tại bang New South Wales

5.1.1 Mục tiêu

Biểu đồ được xây dựng nhằm trực quan hóa sự phân bố giá nhà theo tọa độ địa lý trên toàn bang New South Wales. Mục tiêu chính là xác định các khu vực có mức giá cao hoặc thấp, qua đó nhận diện “vùng nóng” của thị trường bất động sản. Kết quả giúp đánh giá mức độ tập trung giá nhà theo khu vực và hỗ trợ định hướng nghiên cứu, đầu tư hoặc quy hoạch phát triển đô thị trong tương lai.



Hình 1: Heatmap Price NSW


5.1.2 Kết luận

Bản đồ cho thấy giá nhà tập trung cao tại khu vực Sydney và các vùng phụ cận phía Đông, phản ánh đặc điểm đô thị hóa mạnh và nhu cầu nhà ở lớn. Khi di chuyển ra xa trung tâm, mức giá giảm dần, thể hiện sự chênh lệch rõ rệt giữa thành thị và nông thôn. Kết quả này cho thấy thị trường bất động sản NSW có tính tập trung cao và chu kỳ tăng giá chủ yếu xoay quanh khu vực đô thị lớn, tạo nền tảng cho các phân tích chuyên sâu về xu hướng đầu tư theo vị trí.

5.2 So sánh giá bất động sản theo loại hình (Type) trên khu vực New South Wales

5.2.1 Mục tiêu

Biểu đồ được xây dựng nhằm so sánh giá nhà trung vị giữa các loại hình bất động sản ở từng vùng của bang New South Wales (NSW). Mục tiêu chính là nhận diện sự khác biệt về mức giá giữa các khu vực đô thị và vùng ngoại ô, đồng thời xác định loại hình nhà ở phổ biến và có giá trị cao nhất trong mỗi khu vực. Kết quả giúp người xem hiểu rõ hơn về cấu trúc giá và xu hướng thị trường bất động sản theo từng vùng địa lý.



Hình 2: Property Price Comparison by Type across NSW Regions

5.2.2 Kết luận

Kết quả cho thấy khu vực Sydney và vùng lân cận có giá trung vị cao nhất, đặc biệt là các loại hình như House và Apartment. Các vùng xa trung tâm như Central West hay Far West có mức giá


thấp hơn đáng kể, phản ánh sự chênh lệch kinh tế và mật độ dân cư giữa các vùng. Nhìn chung, biểu đồ thể hiện mối tương quan rõ rệt giữa vị trí địa lý và giá bất động sản, cho thấy thị trường NSW vẫn tập trung mạnh quanh khu đô thị lớn, trong khi các vùng xa hơn giữ vai trò hỗ trợ với giá thấp và ổn định hơn.

5.3 Bản đồ cụm không gian LISA của giá bất động sản tại bang New South Wales

5.3.1 Mục tiêu

Phần bản đồ được xây dựng nhằm:

- Phân tích sự tự tương quan không gian (*spatial autocorrelation*) của giá nhà tại bang New South Wales (NSW) — tức là xem liệu giá nhà ở một khu vực có xu hướng giống hoặc khác biệt đáng kể so với các khu vực lân cận.
- Phát hiện các cụm (*clusters*) theo mô hình LISA, bao gồm:
 - **Cao–Cao (High–High):** Khu vực có giá nhà cao, bao quanh bởi các khu vực cũng có giá cao.
 - **Thấp–Thấp (Low–Low):** Khu vực có giá thấp, nằm gần các khu vực cũng có giá thấp.
 - **Cao–Thấp (High–Low):** Giá nhà cao nhưng nằm giữa vùng giá thấp → khu “đột biến cao”.
 - **Thấp–Cao (Low–High):** Giá thấp giữa vùng giá cao → khu “đột biến thấp”.



Hình 3: Moran's I - LISA

5.3.2 Kết luận

Dữ liệu giá nhà tại bang NSW thể hiện sự tồn tại rõ rệt của các vùng tập trung giá cao và giá thấp, chứng tỏ giá nhà có tính không gian (*spatial dependence*).

Các cụm **Cao–Cao (đỏ)** thường tập trung tại khu vực trung tâm thành phố hoặc vùng phát triển, nơi thị trường bất động sản sôi động và giá cao. Ngược lại, các cụm **Thấp–Thấp (xanh đậm)** xuất hiện ở vùng ven hoặc ngoại ô, thể hiện xu hướng tập trung của các khu vực có giá nhà thấp. Các vùng **Cao–Thấp** và **Thấp–Cao** (màu vàng và xanh nhạt) đại diện cho các khu vực chuyển tiếp, có thể đang trong giai đoạn phát triển hoặc biến động về giá.

Kết quả phân tích này giúp xác định các khu vực có xu hướng bất thường về giá nhà, hỗ trợ quá trình **hoạch định chính sách, đầu tư và quy hoạch đô thị** một cách hiệu quả hơn.

5.4 5 loại hình bất động sản được bán nhiều nhất

5.4.1 Mục tiêu

Phân tích xu hướng thay đổi số lượng giao dịch bất động sản theo từng loại hình (*property type*) tại bang New South Wales (NSW) trong giai đoạn 5 năm gần nhất, nhằm theo dõi xu hướng giao dịch qua từng năm và xác định loại hình chiếm ưu thế trên thị trường. Trực quan hóa dữ liệu bằng biểu đồ đường (*Line Chart*) để dễ dàng quan sát tốc độ tăng/giảm của từng loại hình qua các năm.



Hình 4: Top 5 loại hình bất động sản được bán nhiều nhất

5.4.2 Kết luận

- Nhóm **“Other”** (bao gồm *House, Unit, Townhouse, Land, Villa*) chiếm tỷ trọng giao dịch cao nhất, duy trì ổn định quanh mức trên 100.000 giao dịch mỗi năm, cho thấy đây là nhóm tổng hợp có sức hút lớn nhất trên thị trường.
- **“Vacant Land”** và **“Commercial”** đứng ở các vị trí kế tiếp, duy trì mức giao dịch trung bình từ vài nghìn đến hàng chục nghìn đơn vị, thể hiện nhu cầu ổn định đối với đất trống và bất động sản thương mại.
- **“Rural/Acreage”** có xu hướng giảm nhẹ, phản ánh sự suy yếu trong đầu tư bất động sản

khu vực nông thôn.


- **“Apartment/Unit”** duy trì số lượng giao dịch thấp và biến động mạnh qua các năm, cho thấy phân khúc này kém sôi động hơn hẳn so với các loại hình khác.

Tổng thể, thị trường NSW giai đoạn 2021–2025 duy trì ổn định, không có biến động lớn về cơ cấu loại hình bất động sản, phản ánh tính bền vững của nhu cầu nhà đất tại khu vực này.

5.5 Mật độ (Hexbin) giá và diện tích bất động sản tại bang New South Wales (NSW)

5.5.1 Mục tiêu

Phần này nhằm xác định mối quan hệ giữa **giá bán (Price)** và **diện tích (Size)** của bất động sản tại bang New South Wales (NSW), đồng thời phát hiện các khu vực có **mật độ giao dịch cao**. Biểu đồ *Hexbin* được sử dụng để trực quan hóa hàng chục nghìn điểm dữ liệu, giúp thể hiện rõ **mức độ phân bố** và **xu hướng giá theo diện tích**.



Hình 5: Biểu đồ mật độ (Hexbin) giữa giá bán và diện tích bất động sản tại NSW

5.5.2 Kết luận


- **Mật độ điểm cao** (vùng vàng–xanh lá) tập trung chủ yếu quanh **diện tích dưới 600 m²** và **giá dưới 1 triệu AUD**, cho thấy đây là nhóm nhà ở phổ biến nhất.
- Khi **diện tích tăng**, **giá cũng có xu hướng tăng**, tuy nhiên mức độ phân tán (vùng xanh–tím) cũng lớn hơn — phản ánh sự khác biệt rõ giữa các loại hình như đất trống, biệt thự hoặc bất động sản thương mại.
- Một số điểm rời rạc tại vùng **>2000 m²** và **>3 triệu AUD** biểu thị các bất động sản cao cấp, ít xuất hiện hơn trên thị trường.
- Mối quan hệ giữa giá và diện tích là **tỷ lệ thuận nhưng không tuyến tính**, cho thấy **vị trí và loại hình bất động sản** cũng là những yếu tố ảnh hưởng mạnh đến giá.

Nhìn chung, biểu đồ cho thấy sự **phân tầng rõ rệt** và **đa dạng** trong thị trường bất động sản NSW, với xu hướng giá tăng theo diện tích nhưng chịu tác động đồng thời của nhiều yếu tố khác.

5.6 Phân bố giá bất động sản tại Sydney

5.6.1 Mục tiêu

Biểu đồ *Scatter* này nhằm xác định các khu vực có **giá bất động sản cao (hotspots)** tại Sydney, thông qua phân tích mối quan hệ giữa **tọa độ địa lý (vĩ độ, kinh độ)** và **giá nhà (Price)**. Bằng cách lọc dữ liệu trong phạm vi **60 km quanh trung tâm Sydney** và loại bỏ các **ngoại lệ (1–99%)**, biểu đồ giúp nhận diện rõ sự **phân bố không gian của giá trị bất động sản**.



Hình 6: Biểu đồ Scatter thể hiện sự phân bố không gian của giá bất động sản tại Sydney

5.6.2 Kết luận

- **Giá nhà tập trung cao nhất** quanh trung tâm Sydney, đặc biệt tại các **khuvực ven cảng** và **khunội thành**.
- Màu **vàng–xanh lục** biểu thị các **điểm nóng về giá (price hotspots)**, trong khi **vùng ngoại ô xa hơn** (màu **tím–xanh dương**) có mức giá thấp hơn rõ rệt.
- Xu hướng giá **giảm dần khi rời xa trung tâm thành phố** cho thấy **sự chênh lệch giá địa lý rõ rệt** trong thị trường bất động sản Sydney.

Nhìn chung, biểu đồ cho thấy cấu trúc **phân tầng không gian rõ rệt** của giá bất động sản Sydney

— trung tâm thành phố vẫn là vùng có mật độ giá cao nhất, phản ánh **tác động mạnh của vị trí địa lý** đối với giá trị nhà ở.


5.7 So sánh giá bất động sản giữa các loại hình nhà ở tại New South Wales

5.7.1 Mục tiêu

Biểu đồ *Violin* này nhằm so sánh sự phân bố giá bất động sản (**Price**) giữa các loại hình nhà ở khác nhau tại bang **New South Wales (NSW)**. Mỗi “*violin*” biểu thị phạm vi giá từ thấp đến cao, trong đó:

- Phần rộng biểu thị khu vực có mật độ giá tập trung nhiều.
- Đường ngang dày ở giữa là giá trung bình (mean).
- Đường ngang mảnh hơn là trung vị (median).

Trục tung thể hiện giá (đơn vị **AUD**) theo **thang logarit**, giúp dễ so sánh các loại hình có khoảng chênh lệch giá lớn.



Hình 7: Biểu đồ Violin thể hiện phân bố giá giữa các loại hình nhà ở tại NSW

5.7.2 Kết luận


- Biểu đồ cho thấy **sự chênh lệch rõ rệt** về giá giữa các loại hình nhà ở tại NSW, phản ánh **độ đa dạng của thị trường** từ cao cấp (House, Terrace/Row) đến trung cấp (Apartment, Townhouse).
- Xuất hiện **chu kỳ giá ổn định** — các loại hình cao cấp vẫn duy trì vị thế qua thời gian, trong khi nhóm trung cấp ít biến động hơn.
- Dữ liệu cho thấy **sự tập trung mạnh theo loại hình**, hữu ích cho **định giá, phân khúc thị trường** và **dự báo xu hướng đầu tư tương lai**.

Nhìn sâu hơn, biểu đồ *Violin* không chỉ là hình ảnh của giá — nó là **đường cong của sự đa dạng đô thị**, nơi mỗi loại nhà kể lại câu chuyện riêng: từ những dãy Terrace cổ kính của Sydney đến các căn hộ cao tầng phản chiếu ánh hoàng hôn. Một bức chân dung kinh tế – xã hội, gói trọn trong hình dáng đối xứng của dữ liệu.

5.8 Mối quan hệ giữa giá trung vị bất động sản và khoảng cách tới trung tâm Sydney

5.8.1 Mục tiêu

Biểu đồ này nhằm thể hiện **mối quan hệ giữa giá trung vị (Median Price) của bất động sản và khoảng cách tới trung tâm Sydney (CBD)**. Dữ liệu được chia thành các **khoảng cách 5 km (5 km bins)** để quan sát rõ hơn xu hướng biến thiên giá theo vị trí địa lý.



Hình 8: Biểu đồ thể hiện mối quan hệ giữa giá trung vị và khoảng cách tới trung tâm Sydney

5.8.2 Kết luận

- Biểu đồ cho thấy **mối quan hệ nghịch đảo giữa giá bất động sản và khoảng cách tới trung tâm Sydney (CBD)**.
- Nhà gần trung tâm có giá cao nhờ **vị trí thuận lợi, hệ thống giao thông phát triển, cơ hội việc làm và tiện ích xã hội** dày đặc.
- Khi ra xa hơn, giá giảm mạnh do **mật độ dân cư thưa thớt, dịch vụ ít hơn và cơ hội kinh tế hạn chế**.


- Tuy nhiên, một số khu vực xa trung tâm vẫn có **mức giá nhỉnh hơn trung bình**, cho thấy **tiềm năng phát triển đô thị và cơ hội đầu tư trong tương lai**.

Tổng thể, biểu đồ phản ánh quy luật **“giá trị giảm theo khoảng cách”** nhưng cũng hé mở các **điểm cân bằng mới của đô thị hiện đại**, nơi vùng ven không còn chỉ là ngoại biên — mà đang trở thành **vệ tinh phát triển song song** cùng trung tâm Sydney.

5.9 Phân bố loại hình bất động sản trong phạm vi 10 km từ bờ biển tại New South Wales

5.9.1 Mục tiêu

Phân tích này nhằm **xác định các loại hình bất động sản phổ biến nhất** nằm trong phạm vi 10 km tính từ bờ biển tại bang New South Wales (NSW). Mục tiêu là giúp **hiểu rõ xu hướng phát triển và nhu cầu thị trường nhà đất ven biển** — nơi thường có **giá trị cao**, đồng thời được **ưa chuộng để ở hoặc đầu tư**.



Hình 9: Phân bố loại hình bất động sản trong phạm vi 10 km từ bờ biển tại NSW

5.9.2 Kết luận

- Khu vực **ven biển NSW** tập trung chủ yếu các loại hình **nhà ở nhỏ gọn, mật độ cao** như **Terrace, Studio, và Apartment**.


- Điều này phản ánh **xu hướng đô thị hóa ven biển** — ưu tiên **không gian sống tiện lợi**, phù hợp với **lối sống hiện đại hoặc đầu tư du lịch**.
- Ngược lại, các loại hình **sang trọng như Penthouse hay Villa** ít phổ biến hơn do **chi phí cao và giới hạn về diện tích xây dựng**.

Tổng thể, biểu đồ cho thấy **thị trường bất động sản ven biển NSW phát triển đa dạng** nhưng vẫn duy trì **hai trụ cột chính: Terrace và Studio** — đại diện cho hai hướng nhu cầu song song giữa **sinh hoạt đô thị năng động và đầu tư ngắn hạn sinh lợi**.

5.10 Phân bố loại hình bất động sản tại bang có giá trung bình trên mỗi mét vuông cao nhất (New South Wales)

5.10.1 Mục tiêu

Phân tích này nhằm **xác định các loại hình bất động sản phổ biến nhất** tại bang có **giá trung bình trên mỗi mét vuông (Price per Square Meter) cao nhất** — cụ thể là **New South Wales (NSW)**. Mục tiêu chính là **hiểu rõ cấu trúc thị trường bất động sản** tại khu vực đắt đỏ nhất, từ đó rút ra nhận định về **xu hướng phát triển và nhu cầu nhà ở** của cư dân.



Hình 10: Phân bố loại hình bất động sản tại bang New South Wales (bang có giá/m² cao nhất)

5.10.2 Kết luận

- Thị trường bất động sản tại **NSW** — bang có **giá trung bình/m² cao nhất** — tập trung mạnh vào các **loại nhà ở mật độ cao, diện tích nhỏ đến trung bình**, đặc biệt là **Semi-detached, Terrace** và **Studio**.
- Điều này phản ánh **xu hướng đô thị hóa mạnh** cùng **quỹ đất hạn chế**, khiến các **dự án chung cư, nhà liền kề và căn hộ mini** trở nên phổ biến.
- Các loại hình **sang trọng** như **Penthouse** hay **Development Site** xuất hiện ít, thể hiện **sự tập trung cục bộ của phân khúc cao cấp** nhưng chỉ chiếm phần nhỏ trong tổng thể thị trường.

Tổng thể, thị trường bất động sản tại NSW cho thấy một **mô hình phát triển cân đối** — trong đó **phân khúc trung bình và đô thị chiếm ưu thế**, phản ánh sự **thích ứng của người dân** với không gian sống nhỏ gọn, tiện nghi giữa bối cảnh **đô thị hóa nhanh** và **giá đất leo thang**.

6 Xây dựng mô hình

6.1 Mục tiêu

Trong giai đoạn mô hình hóa, nhóm tiến hành huấn luyện và đánh giá nhiều mô hình khác nhau để dự đoán giá nhà. Các mô hình được lựa chọn gồm: Linear Regression, Decision Tree, Random Forest, Gradient Boosting và XGBoost.

6.2 Linear Regression

6.2.1 Tổng quan lý thuyết

Hồi quy tuyến tính là phương pháp mô tả mối quan hệ tuyến tính giữa một biến mục tiêu y và một hoặc nhiều biến độc lập x . Dạng mô hình (hàm giả thiết) cho m đặc trưng là:

$$\hat{y} = h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_m x_m$$

Trong dạng vectơ, viết gọn:

$$\hat{y} = h_{\theta}(x) = \mathbf{x}^{\top} \boldsymbol{\theta}$$

với $\mathbf{x} = [1, x_1, \dots, x_m]^{\top}$.

6.2.2 Hàm mất mát (Loss Function) và hàm mục tiêu (Cost Function)

Để ước lượng tham số $\boldsymbol{\theta}$, ta tối thiểu hoá tổng bình phương sai số (Sum of Squared Errors). Thường dùng **Mean Squared Error (MSE)** hoặc biến thể có hệ số $\frac{1}{2n}$ để thuận tiện khi làm gradient descent:

MSE (Mean Squared Error):

$$\text{MSE}(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n (\hat{y}^{(i)} - y^{(i)})^2$$

Cost function (thường dùng cho gradient descent):

$$J(\theta) = \frac{1}{2n} \sum_{i=1}^n (\hat{y}^{(i)} - y^{(i)})^2$$

Ghi chú: Hệ số $\frac{1}{2}$ giúp đơn giản hoá đạo hàm của J (loại bỏ 2 đứng trước sum khi lấy gradient).

6.2.3 Chỉ số đánh giá hiệu năng

- MAE (Mean Absolute Error):

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |\hat{y}^{(i)} - y^{(i)}|$$

- RMSE (Root Mean Squared Error):

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}^{(i)} - y^{(i)})^2}$$

- R^2 (Coefficient of Determination):

$$R^2 = 1 - \frac{\sum_{i=1}^n (y^{(i)} - \hat{y}^{(i)})^2}{\sum_{i=1}^n (y^{(i)} - \bar{y})^2}$$

trong đó $\bar{y}$ là giá trị trung bình của y .

6.2.4 Triển khai

```

1 lr_pipe = Pipeline(steps=[
2     ('preprocessor', preprocessor),
3     ('model', LinearRegression())
4 ])
5
6 lr_pipe.fit(X_train, y_train)
7
8 y_pred_lr = lr_pipe.predict(X_test)
9
10 lr_mae = mean_absolute_error(y_test, y_pred_lr)

```

```
11 lr_rmse = np.sqrt(mean_squared_error(y_test, y_pred_lr))
12 lr_r2 = r2_score(y_test, y_pred_lr)
```

6.2.5 Kết quả và nhận xét

Kết quả huấn luyện mô hình hồi quy tuyến tính trên tập dữ liệu kiểm thử (test set):

$$\text{MAE} = 490,522.15, \quad \text{RMSE} = 881,730.26, \quad R^2 = 0.2306$$

Nhận xét:

- **MAE** khoảng 490 nghìn AUD cho thấy sai số trung bình tuyệt đối giữa giá dự đoán và giá thực tế ở mức khá cao — điều này cho thấy mô hình còn hạn chế trong việc nắm bắt đầy đủ các yếu tố ảnh hưởng đến giá nhà.
- **RMSE** cao hơn đáng kể (khoảng 881 nghìn AUD), thể hiện sự tồn tại của một số điểm có sai số lớn (outlier hoặc các trường hợp giá đặc biệt).
- $R^2 = 0.2306$ nghĩa là mô hình chỉ giải thích được khoảng 23.06% phương sai của giá nhà trong dữ liệu. Đây là mức độ vừa phải, cho thấy mối quan hệ tuyến tính giữa các biến đầu vào và giá nhà là có tồn tại nhưng yếu.

Kết luận: Mô hình hồi quy tuyến tính đóng vai trò là **baseline** — đơn giản, dễ giải thích và nhanh huấn luyện. Tuy kết quả chưa cao, nhưng đây là cơ sở ban đầu để so sánh với các mô hình nâng cao hơn trong các bước tiếp theo.

6.3 Decision Tree Regression

6.3.1 Tổng quan lý thuyết

Decision Tree Regression (hồi quy cây quyết định) là một phương pháp mô hình hoá phi tuyến, chia không gian đặc trưng thành các vùng nhỏ thông qua việc ra quyết định nhị phân liên tiếp dựa trên các giá trị thuộc tính. Ở mỗi nút chia (split node), thuật toán chọn đặc trưng x_j và ngưỡng chia t sao cho giúp giảm thiểu sai số dự đoán trong hai nhánh con.

Hàm chia (Split Function): Một phép chia được định nghĩa là:

$$Q = \{(x_i, y_i)\}_{i=1}^N \rightarrow \begin{cases} Q_{\text{left}} = \{(x_i, y_i) | x_{ij} \leq t\} \\ Q_{\text{right}} = \{(x_i, y_i) | x_{ij} > t\} \end{cases}$$

Tiêu chí chọn split (Impurity Function): Với bài toán hồi quy, tiêu chí phổ biến nhất là **Giảm phương sai (Variance Reduction):**

$$\Delta I = I(Q) - \frac{N_L}{N} I(Q_L) - \frac{N_R}{N} I(Q_R)$$

trong đó:

$$I(Q) = \frac{1}{|Q|} \sum_{(x_i, y_i) \in Q} (y_i - \bar{y}_Q)^2$$

là phương sai của nút hiện tại, và Q_L, Q_R là hai tập con sau khi chia.

Mục tiêu là tìm ra split (x_j, t) sao cho ΔI là lớn nhất.

Giá trị dự đoán tại lá (Leaf Prediction): Sau khi cây được xây dựng, giá trị dự đoán tại mỗi lá được tính bằng trung bình giá trị thực của các điểm trong lá đó:

$$\hat{y}_{\text{leaf}} = \frac{1}{|Q_{\text{leaf}}|} \sum_{(x_i, y_i) \in Q_{\text{leaf}}} y_i$$

6.3.2 Triển khai

```
1 dt_pipe = Pipeline(steps=[
2     ('preprocessor', preprocessor),
3     ('model', DecisionTreeRegressor(random_state=42))
4 ])
5
6 dt_pipe.fit(X_train, y_train)
7
8 y_pred_dt = dt_pipe.predict(X_test)
9
10 dt_mae = mean_absolute_error(y_test, y_pred_dt)
11 dt_rmse = np.sqrt(mean_squared_error(y_test, y_pred_dt))
```

```
12 dt_r2 = r2_score(y_test, y_pred_dt)
```

6.3.3 Kết quả và nhận xét

Kết quả huấn luyện mô hình Decision Tree trên tập dữ liệu kiểm thử (test set):

$$\text{MAE} = 61,092.36, \quad \text{RMSE} = 314,125.93, \quad R^2 = 0.9023$$

Nhận xét:

- **MAE** chỉ khoảng 61 nghìn AUD, thấp hơn đáng kể so với mô hình Linear Regression, cho thấy dự đoán của mô hình chính xác hơn nhiều.
- **RMSE** cũng thấp (khoảng 314 nghìn AUD), cho thấy sai số bình phương trung bình nhỏ và mô hình xử lý tốt cả các điểm ngoại lệ.
- **$R^2 = 0.9023$** chứng tỏ mô hình giải thích được hơn 90% phương sai của giá nhà — thể hiện khả năng khớp dữ liệu rất tốt.

Kết luận: Mô hình Decision Tree cho kết quả vượt trội so với Linear Regression, thể hiện khả năng học tốt các quy luật phức tạp trong dữ liệu. Tuy nhiên, cần kiểm soát độ sâu cây để tránh overfitting và đảm bảo khả năng áp dụng thực tế.

6.4 Random Forest Regression

6.4.1 Tổng quan lý thuyết

Random Forest Regression là một mô hình **ensemble learning** (học tập tổ hợp), được xây dựng dựa trên việc kết hợp nhiều cây quyết định (*Decision Trees*) độc lập. Ý tưởng chính là sử dụng trung bình dự đoán của nhiều cây khác nhau để giảm phương sai và cải thiện khả năng tổng quát hoá của mô hình.

Nguyên lý hoạt động:

- Tập dữ liệu huấn luyện được lấy mẫu ngẫu nhiên có hoàn lại (bootstrap sampling) để tạo ra nhiều tập con.

- Mỗi cây trong rừng được huấn luyện độc lập trên một tập con dữ liệu khác nhau và chỉ xét ngẫu nhiên một tập nhỏ các đặc trưng khi chia nút.
- Dự đoán cuối cùng là trung bình của tất cả các cây trong rừng:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T h_t(x)$$

trong đó $h_t(x)$ là dự đoán của cây thứ t , và T là tổng số cây.

6.4.2 Triển khai

```

1 rf_pipe = Pipeline(steps=[
2     ('preprocessor', preprocessor),
3     ('model', RandomForestRegressor(
4         n_estimators=100,
5         random_state=42,
6         n_jobs=-1
7     )))
8 ])
9
10 rf_pipe.fit(X_train, y_train)
11
12 y_pred_rf = rf_pipe.predict(X_test)
13
14 rf_mae = mean_absolute_error(y_test, y_pred_rf)
15 rf_rmse = np.sqrt(mean_squared_error(y_test, y_pred_rf))
16 rf_r2 = r2_score(y_test, y_pred_rf)

```

6.4.3 Kết quả và nhận xét

Kết quả huấn luyện mô hình Random Forest trên tập dữ liệu kiểm thử (test set):

$$\text{MAE} = 56,591.62, \quad \text{RMSE} = 302,163.56, \quad R^2 = 0.9096$$

Nhận xét:

- **MAE** chỉ khoảng 56 nghìn AUD, thấp nhất trong ba mô hình đã thử nghiệm, thể hiện độ chính xác cao trong dự đoán giá nhà.
- **RMSE** ở mức 302 nghìn AUD, cho thấy sai số bình phương trung bình đã giảm đáng kể so với Decision Tree, chứng minh khả năng tổng quát tốt hơn.
- $R^2 = 0.9096$ nghĩa là mô hình giải thích được hơn 90.96% phương sai của biến giá nhà, đạt hiệu năng rất cao và ổn định.

Random Forest Regression đạt hiệu năng cao nhất trong ba mô hình được thử nghiệm, chứng minh là lựa chọn phù hợp cho bài toán dự đoán giá nhà trong dữ liệu phức tạp và phi tuyến. Mô hình cân bằng tốt giữa độ chính xác và khả năng tổng quát, nên có thể được sử dụng làm chuẩn tham chiếu (*benchmark*) cho các mô hình nâng cao hơn như Gradient Boosting hoặc XGBoost.

6.5 Gradient Boosting Regression

6.5.1 Tổng quan lý thuyết

Gradient Boosting Regression là một mô hình **ensemble learning** thuộc nhóm **boosting**, trong đó nhiều cây quyết định yếu (*weak learners*) được xây dựng tuần tự. Mỗi cây mới được huấn luyện nhằm giảm thiểu sai số còn lại (*residuals*) của mô hình trước đó, nhờ đó cải thiện dần hiệu năng tổng thể.

Nguyên lý hoạt động:

- Bắt đầu với một mô hình cơ bản (thường là giá trị trung bình của nhãn đầu ra).
- Tại mỗi bước, tính toán phần dư ($r_i = y_i - \hat{y}_i$) — tức là sai lệch giữa giá trị thực và dự đoán hiện tại.
- Huấn luyện một cây quyết định mới $h_t(x)$ để dự đoán phần dư r_i .
- Cập nhật mô hình bằng cách cộng thêm đóng góp có trọng số từ cây mới:

$$F_t(x) = F_{t-1}(x) + \eta \cdot h_t(x)$$

trong đó η là *learning rate*, điều chỉnh mức ảnh hưởng của mỗi cây mới.

- Quá trình lặp lại cho đến khi đạt được số cây T hoặc sai số hội tụ.

6.5.2 Triển khai

```

1 gb_pipe = Pipeline(steps=[
2     ('preprocessor', preprocessor),
3     ('model', GradientBoostingRegressor(
4         n_estimators=500,
5         learning_rate=0.05,
6         max_depth=5,
7         min_samples_split=10,
8         min_samples_leaf=4,
9         random_state=42
10    ))
11 ])
12
13 gb_pipe.fit(X_train, y_train)
14 y_pred_gb = gb_pipe.predict(X_test)

```

6.5.3 Kết quả và nhận xét

Kết quả huấn luyện mô hình Gradient Boosting trên tập dữ liệu kiểm thử (test set):

$$\text{MAE} = 110,292.31, \quad \text{RMSE} = 427,244.49, \quad R^2 = 0.8193$$

Nhận xét:

- **MAE** ở mức 110 nghìn AUD, cao hơn đáng kể so với Random Forest, cho thấy sai số trung bình lớn hơn trong dự đoán.
- **RMSE** đạt 427 nghìn AUD, phản ánh mô hình chưa tối ưu trong việc xử lý các sai số lớn.
- $R^2 = 0.8193$ nghĩa là mô hình chỉ giải thích được khoảng 81.93% phương sai của giá nhà — thấp hơn so với Random Forest, cho thấy khả năng tổng quát kém hơn trong trường hợp này.

Mặc dù **Gradient Boosting Regression** thường có tiềm năng mạnh hơn Random Forest trong việc tối ưu sai số nhờ quá trình học tuần tự, nhưng trong thí nghiệm này, hiệu năng chưa vượt trội.

Nguyên nhân có thể do các siêu tham số (*hyperparameters*) như *learning rate* và độ sâu cây (*max depth*) chưa được tinh chỉnh tối ưu. Tuy nhiên, mô hình vẫn đạt kết quả tốt với $R^2 \approx 0.82$, chứng tỏ khả năng nắm bắt xu hướng phi tuyến của dữ liệu.

6.6 XGBoost Regression

6.6.1 Tổng quan lý thuyết

XGBoost (*Extreme Gradient Boosting*) là một phiên bản nâng cao của mô hình **Gradient Boosting**, được tối ưu hoá về cả tốc độ huấn luyện lẫn hiệu năng dự đoán. Thuật toán này sử dụng cách tiếp cận **gradient boosting có điều chuẩn** (*regularized gradient boosting*), giúp kiểm soát độ phức tạp của cây, từ đó giảm hiện tượng *overfitting*.

Nguyên lý hoạt động:

- XGBoost vẫn dựa trên ý tưởng cơ bản của boosting: xây dựng nhiều cây liên tiếp, trong đó mỗi cây mới cố gắng sửa lỗi của cây trước.
- Hàm mất mát tổng quát của XGBoost có dạng:

$$\mathcal{L} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t)}) + \sum_{k=1}^t \Omega(f_k)$$

trong đó:

$$\Omega(f_k) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

với $\Omega(f_k)$ là thành phần điều chuẩn giúp giới hạn độ phức tạp của mô hình (số lá T và trọng số w_j).

- Sử dụng kỹ thuật **shrinkage** (learning rate nhỏ) và **subsampling** để tăng khả năng tổng quát hoá.

6.6.2 Triển khai

```
1 xgb_pipe = Pipeline(steps=[
2     ('preprocessor', preprocessor),
```

```

3      ('model', XGBRegressor(
4          n_estimators=10000,
5          learning_rate=0.001,
6          max_depth=8,
7          subsample=0.7,
8          colsample_bytree=0.7,
9          min_child_weight=10,
10         reg_lambda=2,
11         reg_alpha=1,
12         random_state=42,
13         n_jobs=-1,
14         tree_method='hist'
15     ))
16 ])
17
18 xgb_pipe.fit(X_train, y_train)
19 y_pred_xgb = xgb_pipe.predict(X_test)

```

6.6.3 Kết quả và nhận xét

Kết quả huấn luyện mô hình XGBoost trên tập dữ liệu kiểm thử (test set):

$$\text{MAE} = 117,768.63, \quad \text{RMSE} = 425,141.32, \quad R^2 = 0.8211$$

Nhận xét:

- **MAE** đạt khoảng 117 nghìn AUD — cao hơn so với Gradient Boosting và Random Forest, cho thấy sai số trung bình vẫn còn đáng kể.
- **RMSE** là 425 nghìn AUD, khá tương đồng với Gradient Boosting, cho thấy mức độ ổn định của mô hình.
- **$R^2 = 0.8211$** cho thấy mô hình giải thích được khoảng 82.11% phương sai của biến giá nhà — hiệu năng tương đương Gradient Boosting.

Mặc dù XGBoost thường được kỳ vọng đạt kết quả vượt trội nhờ cơ chế tối ưu hóa và điều chuẩn mạnh, trong trường hợp này, mô hình chưa thể hiện rõ ưu thế.

XGBoost Regression cho hiệu năng khá ổn định với $R^2 \approx 0.82$, tuy nhiên chưa vượt qua Random Forest. Để đạt kết quả tốt hơn, có thể tinh chỉnh thêm các siêu tham số (*hyperparameters*) như *learning rate*, *n_estimators*, và *max_depth* hoặc áp dụng *early stopping*. Dù vậy, XGBoost vẫn là một mô hình mạnh mẽ, phù hợp để cải thiện thêm hiệu suất dự đoán khi được tối ưu hoá đúng cách.

6.7 Tối ưu siêu tham số bằng Optuna

6.7.1 Tổng quan

Để nâng cao hiệu năng của các mô hình học máy, nhóm đã sử dụng **Optuna** — một thư viện tối ưu hoá siêu tham số tự động (auto hyperparameter tuning) mạnh mẽ. Phương pháp này giúp tìm ra tổ hợp siêu tham số tốt nhất cho từng mô hình dựa trên quá trình thử nghiệm lặp lại (*trial*) và cơ chế cắt tỉa (*pruning*) các cấu hình kém tiềm năng.

Ba mô hình được tinh chỉnh trong thí nghiệm gồm:

- **Random Forest Regressor**
- **Gradient Boosting Regressor**
- **XGBoost Regressor**

Tiêu chí đánh giá được sử dụng trong quá trình tối ưu là **Mean Absolute Error (MAE)**, thông qua **3-fold cross-validation** trên tập huấn luyện.

6.7.2 Không gian tìm kiếm siêu tham số

Các siêu tham số được Optuna tìm kiếm ngẫu nhiên trong khoảng xác định như sau:

1. Random Forest:

- $n_estimators \in [100, 500]$
- $max_depth \in [10, 30]$
- $min_samples_split \in [2, 20]$
- $min_samples_leaf \in [1, 10]$

- $max_features \in \{\text{sqrt}, \text{log2}, 0.3, 0.5\}$

2. Gradient Boosting:

- $n_estimators \in [300, 1000]$
- $learning_rate \in [0.01, 0.2]$
- $max_depth \in [3, 10]$
- $min_samples_split \in [5, 30]$
- $min_samples_leaf \in [2, 15]$
- $subsample \in [0.6, 1.0]$
- $max_features \in \{\text{sqrt}, \text{log2}, 0.3, 0.5\}$

3. XGBoost:

- $n_estimators \in [500, 2000]$
- $learning_rate \in [0.001, 0.1]$
- $max_depth \in [5, 15]$
- $subsample, colsample_bytree \in [0.6, 1.0]$
- $min_child_weight \in [1, 20]$
- $reg_alpha, reg_lambda, \gamma \in [0, 5]$

Mỗi mô hình được chạy trong **30 trial**, và Optuna tự động loại bỏ các trial có kết quả tệ hơn dựa trên cơ chế *median pruning*.

6.7.3 Kết quả tối ưu hoá

Sau quá trình chạy, Optuna đã tìm được các cấu hình tốt nhất cho từng mô hình như sau:

1. Random Forest Regressor

`n_estimators: 481`

`max_depth: 28`

`min_samples_split: 11`

min_samples_leaf: 3

max_features: 0.5

Kết quả trên tập kiểm thử (test set):

$$\text{MAE} = 69,701.60, \quad \text{RMSE} = 327,929.85, \quad R^2 = 0.8936$$

2. Gradient Boosting Regressor

n_estimators: 856

learning_rate: 0.056321002427873336

max_depth: 10

min_samples_split: 21

min_samples_leaf: 12

subsample: 0.9773127053661743

max_features: 0.3

Kết quả trên tập kiểm thử:

$$\text{MAE} = 88,656.87, \quad \text{RMSE} = 347,296.30, \quad R^2 = 0.8806$$

3. XGBoost Regressor

n_estimators: 1315

learning_rate: 0.06173728467372619

max_depth: 13

subsample: 0.7344695442536173

colsample_bytree: 0.9490426171793362

min_child_weight: 8

reg_alpha: 2.162710054589269

reg_lambda: 3.3328393191284675

gamma: 2.845816326659519

Kết quả trên tập kiểm thử:

$$\text{MAE} = 73,875.42, \quad \text{RMSE} = 312,654.53, \quad R^2 = 0.9033$$

6.8 Kết luận

6.8.1 So sánh tổng hợp

Bảng 4: So sánh hiệu năng giữa các mô hình

Mô hình	MAE	RMSE	R^2
Linear Regression	490,522.15	881,730.26	0.2306
Decision Tree	61,092.36	314,125.93	0.9023
Random Forest	56,591.62	302,163.56	0.9096
Gradient Boosting	110,292.31	427,244.49	0.8193
XGBoost	117,768.63	425,141.32	0.8211
Random Forest (after optimization)	69,701.60	327,929.85	0.8936
Gradient Boosting (after optimization)	88,656.87	347,296.30	0.8806
XGBoost (after optimization)	73,875.42	312,654.53	0.9033

6.8.2 Nhận xét

- Kết quả cho thấy **Linear Regression** có hiệu năng thấp nhất với $R^2 = 0.2306$, cho thấy quan hệ giữa đặc trưng và giá nhà không mang tính tuyến tính rõ ràng.
- **Decision Tree Regressor** cải thiện đáng kể hiệu năng ($R^2 = 0.9023$), song vẫn dễ bị quá khớp do đặc trưng mô hình đơn cây.
- **Random Forest Regressor** đạt kết quả tốt nhất trong tất cả mô hình với $R^2 = 0.9096$, MAE = 56,592 AUD và RMSE = 302,164 AUD — thể hiện khả năng khái quát và độ ổn định vượt trội.
- Các mô hình **Gradient Boosting** và **XGBoost** ban đầu có hiệu năng thấp hơn (R^2 chỉ khoảng 0.82), cho thấy cần tinh chỉnh thêm siêu tham số để phát huy tối đa sức mạnh.
- Sau khi tối ưu hoá bằng **Optuna**, các mô hình boosting đều được cải thiện rõ rệt:
 - **Gradient Boosting (after optimization)** tăng từ $R^2 = 0.8193$ lên 0.8806, giảm đáng kể sai số dự đoán.
 - **XGBoost (after optimization)** tăng lên $R^2 = 0.9033$, tiệm cận với Random Forest, thể hiện khả năng học tốt hơn sau tinh chỉnh.

- Ngược lại, **Random Forest (after optimization)** giảm nhẹ hiệu năng còn $R^2 = 0.8936$, cho thấy quá trình tối ưu chưa thực sự mang lại cải thiện đối với mô hình này.
- Nhìn chung, dù XGBoost cải thiện đáng kể sau tối ưu, **Random Forest gốc vẫn là mô hình cho hiệu năng tốt nhất** trên toàn bộ tập dữ liệu.

Kết luận: Dựa trên kết quả tổng hợp, **Random Forest Regressor** cho hiệu năng cao nhất với $R^2 = 0.9096$ và sai số thấp nhất trong tất cả các mô hình. Việc tối ưu hoá bằng **Optuna** giúp cải thiện đáng kể hiệu năng của các mô hình boosting, đặc biệt là **XGBoost**, tuy nhiên vẫn chưa thể vượt qua Random Forest về độ chính xác và khả năng khái quát. Do đó, **Random Forest** được xem là lựa chọn phù hợp và ổn định nhất cho bài toán dự đoán giá nhà trong nghiên cứu này.